Strategiczna Architektura Autonomicznego Cyfrowego Bliźniaka Egzoplanetarnego: Fuzja LLM, CGAN oraz PINNFormer w Astrobiologii Obliczeniowej

Wprowadzenie do Zmiany Paradygmatu w Astrobiologii Obliczeniowej i Ewaluacja Koncepcji

Przejście od czysto obserwacyjnej astronomii do predykcyjnej egzoklimatologii stanowi jedną z najgłębszych zmian koncepcyjnych we współczesnej astrofizyce.[1] Historycznie poszukiwania egzoplanet były zdominowane przez statystyczną akumulację odkryć, mającą na celu odpowiedź na fundamentalne pytanie, czy ciała planetarne poza Układem Słonecznym istnieją w znaczących liczbach.[1] Wraz ze strumieniami danych dostarczanymi przez przełomowe misje kosmiczne, takie jak teleskop Kepler, Transiting Exoplanet Survey Satellite (TESS) oraz Kosmiczny Teleskop Jamesa Webba (JWST), działającymi z niespotykaną dotąd rozdzielczością, dyscyplina ta ewoluowała w kierunku niezwykle szczegółowej charakteryzacji atmosfer, struktur geologicznych i powierzchni tych odległych światów.[1] W konsekwencji współczesna astrobiologia staje przed potężnym wyzwaniem analitycznym: zidentyfikowaniem, które z tysięcy potwierdzonych egzoplanet posiadają odpowiednie warunki fizyczne, atmosferyczne i klimatyczne do podtrzymania życia.[1]

Zaproponowana koncepcja stworzenia kompletnego, autonomicznego Cyfrowego Bliźniaka (Agentic Digital Twin), który integruje agenta opartego na Wielkim Modelu Językowym (LLM) jako warstwę orkiestracji, Warunkowe Generatywne Sieci Przeciwstawne (CGAN) do rozszerzania danych oraz innowacyjne architektury fizyczne (PINNFormer, ELM, PI-GAN) jako silnik termodynamiczny, jest koncepcją nie tylko wysoce innowacyjną, ale wręcz rewolucyjną w kontekście standardów hackathonowych.[1] Taka architektura bezpośrednio uderza w rygorystyczne wymagania Kategorii 3 (Zdatność egzoplanet do zamieszkania), która wymaga od zespołów projektowych stworzenia probabilistycznych i fizycznych modeli badających warunki ciśnienia, temperatury oraz stabilności ciekłej wody.[1] Koncepcja ta fenomenalnie adresuje największe bolączki współczesnej analityki astronomicznej: paraliżujący brak danych dla klas mniejszościowych (planet ziemiopodobnych), gigantyczne koszty obliczeniowe klasycznych Modeli Ogólnej Cyrkulacji (GCM) oraz konieczność zachowania fizycznej poprawności symulacji.[1]

Niniejszy raport stanowi dogłębną analizę wykonalności i optymalizacji tego pomysłu. Konstrukcja zorkiestrowanego potoku (pipeline), w którym poszczególne technologie nie działają w izolacji, lecz wymieniają się wielowymiarowymi tensorami danych, pozwala na stworzenie platformy o niespotykanej dotąd elastyczności. Aby jednak projekt wywołał absolutny "Efekt WOW" podczas prezentacji i uzyskał status najlepszego możliwego wdrożenia, konieczne jest wprowadzenie szeregu poprawek architektonicznych, integracja zaawansowanych mechanizmów renderowania trójwymiarowego oraz rygorystyczne ustrukturyzowanie pętli decyzyjnych agenta LLM.[1] Analiza ta dekonstruuje każdą warstwę systemu, proponując konkretne rozwiązania inżynieryjne, matematyczne ramy ewaluacyjne oraz wytyczne dotyczące projektowania interfejsu użytkownika, które przekształcą teoretyczny plan w bezkonkurencyjny, działający w czasie rzeczywistym produkt analityczny.

Fizyczne i Termodynamiczne Podstawy Cyfrowego Bliźniaka

Aby jakikolwiek algorytm uczenia maszynowego – niezależnie czy jest to model generatywny, transformator, czy maszyna wektorów nośnych – mógł pełnić rolę użytecznego cyfrowego bliźniaka, musi on bezwzględnie respektować fundamentalne mechaniki fizyczne dyktujące klimaty planetarne.[1] Model zasilany sztuczną inteligencją jest tylko tak solidny, jak matematyczna fizyka, którą emuluje, dlatego głębokie zrozumienie równań planetarnych jest absolutnym warunkiem wstępnym dla inżynierii cech (feature engineering) i poprawnego formułowania funkcji straty.[1] W architekturze proponowanego systemu, warstwa silnika fizycznego musi natywnie operować na poniższych zjawiskach.

Fundamentalną metryką zdatności do zamieszkania jest teoretyczna zdolność planety do utrzymania ciekłej wody na swojej powierzchni, co definiuje granice ekosfery (Habitable Zone - HZ).[1] Głównym wskaźnikiem warunków panujących na powierzchni planety jest jej temperatura równowagowa. Przy założeniu równomiernej redystrybucji ciepła, wartość ta wywodzi się z klasycznego prawa Stefana-Boltzmanna.[1] Wyraża się ona równaniem, w którym temperatura jest proporcjonalna do pierwiastka czwartego stopnia ze stosunku pochłoniętego strumienia promieniowania gwiazdowego do stałej Stefana-Boltzmanna, skorygowanego o planetarne albedo Bonda, determinujące ułamek energii elektromagnetycznej bezpowrotnie odbijanej w przestrzeń kosmiczną.[1] Chociaż to równanie dostarcza wyidealizowanej linii bazowej niezbędnej do wstępnego filtrowania katalogów (np. za pośrednictwem zapytań SQL do bazy NASA TAP), sztuczna inteligencja musi brać pod uwagę wysoce nieliniowe efekty cieplarniane, gęstość atmosfery oraz złożoną dynamikę cyrkulacyjną.[1]

Kluczową kwestią dla współczesnej egzoklimatologii, która musi zostać zaprogramowana w jądrze cyfrowego bliźniaka, jest zjawisko zablokowania pływowego (tidal locking).[1] Gwiazdy o małej masie, w szczególności czerwone karły typu M, które są niezwykle powszechne we wszechświecie i często goszczą planety typu ziemskiego (jak układ TRAPPIST-1), emitują znacznie mniej energii świetlnej niż gwiazdy typu słonecznego.[1] Wymusza to przebywanie

planet w bardzo bliskich ekosferach, gdzie poddawane są one intensywnym gradientom grawitacyjnym wzdłuż swoich średnic.[1] Przez miliony lat dyssypacja pływowa zmusza okres rotacji planety do synchronizacji z jej okresem orbitalnym.[1] Ramy matematyczne rządzące tym stanem opisywane są złożonymi równaniami różniczkowymi, uwzględniającymi długość podgwiezdną, anomalię średnią oraz stałą dyssypację pływową opóźnienia czasowego.[1]

Dla zespołów programistycznych budujących modele predykcyjne, kluczowe jest parametryzowanie tego zjawiska. Skalę czasową wymaganą do osiągnięcia stanu zablokowania pływowego szacuje się przy użyciu uproszczonego fizycznego przybliżenia zależnego od masy gwiazdy, dystansu orbitalnego oraz parametru pływowego.[1] Parametr ten drastycznie różni się w zależności od kompozycji planety; przyjmuje się wartości rzędu dziesięciu dla planet z grubymi atmosferami lub globalnymi oceanami, podczas gdy wartości o rząd wielkości wyższe stosuje się dla światów pokrytych lądolodami.[1] Zrozumienie tej dynamiki jest absolutnie krytyczne dla silnika fizycznego (PINNFormer/ELM), ponieważ wolno rotująca planeta doświadcza sił Coriolisa, które całkowicie zmieniają globalną cyrkulację atmosferyczną, podczas gdy planeta zablokowana pływowo opiera się niemal wyłącznie na dywergencji substelarnej – gigantycznej różnicy termicznej między nagrzaną stroną dzienną a zamrożoną stroną nocną – w celu transportu ciepła.[1]

Wprowadzenie globalnych oceanów do modelu sprawia, że termodynamiczny transport ciepła (Ocean Heat Transport - OHT) staje się wysoce zlokalizowany, nieliniowy i determinujący dla przetrwania biosfery.[1] Badania oparte na siatkach wysokiej rozdzielczości wykazały, że zablokowane pływowo akwaplanety wykazują odrębne stany klimatyczne opierające się na drastycznych przejściach fazowych materii.[1] Przy słabym transporcie ciepła planeta wchodzi w tak zwany stan "gałki ocznej" (eyeball state), charakteryzujący się okrągłym, niezamarzniętym oceanem zlokalizowanym dokładnie na punkcie podgwiezdnym, podczas gdy cała reszta globu skuta jest grubym lądolodem.[1] Natomiast gdy wysoce wydajne prądy równikowe zaczną efektywnie transportować ciepło, topią one lód na wschód od strefy naświetlenia, skutkując stanem "homara" (lobster state) – wydłużonym oceanem równikowym, który drastycznie powiększa obszar zdatny do zasiedlenia.[1] Brutalne pętle sprzężeń zwrotnych, takie jak sprzężenie lód-albedo, w których ochłodzenie generuje więcej lodu, co odbija więcej światła i prowadzi do globalnego zlodowacenia, muszą być precyzyjnie przewidywane przez architekturę AI.[1]

Warstwa 1: Orkiestracja – Agent LLM jako Kognitywny Mózg Systemu

Zaproponowanie agenta opartego na Wielkim Modelu Językowym (LLM) jako centralnego "Mózgu" systemu to koncepcja, która przekształca pasywny kalkulator w interaktywnego asystenta badawczego. Zamiast manualnie uruchamiać skrypty Pythona do pobierania danych, analizy i renderowania, użytkownik komunikuje się z systemem za pomocą zapytań w języku naturalnym. Agent, wykorzystując paradygmat rozumowania i działania (ReAct - Reason and

Act), samodzielnie planuje kroki analityczne, decyduje, które narzędzia wywołać, oraz syntetyzuje ostateczne wyniki.[1] Jednakże, wdrożenie tej warstwy w rygorystycznym środowisku naukowym wymaga głębokiej optymalizacji.

Modele Fundacyjne Specyficzne dla Domeny (Domain-Specific LLMs)

Wykorzystanie generycznych modeli o zamkniętym kodzie źródłowym niesie ze sobą ogromne ryzyko halucynacji praw fizyki oraz brak precyzji w posługiwaniu się nomenklaturą astronomiczną.[1] Doskonałym usprawnieniem tego projektu jest implementacja specjalistycznych modeli fundacyjnych, takich jak rodzina AstroLLaMA. Modele te, na przykład AstroLLaMA-3.1-8B lub warianty 70B, są fine-tunowane na setkach tysięcy abstraktów z bazy arXiv, tekstach wprowadzających oraz wnioskach z publikacji astrofizycznych, często z wykorzystaniem technik takich jak Supervised Fine-Tuning (SFT) czy Continual Pre-Training (CPT).[1] Wykazują one znacznie niższą perpleksję w tekstach z zakresu nauk planetarnych w porównaniu do standardowych wariantów modeli LLaMA.[9]

Dla zapewnienia płynności i niezależności podczas hackathonu (gdzie dostęp do stabilnego API może być utrudniony), system powinien bazować na lokalnie hostowanym modelu za pośrednictwem platform takich jak Ollama z frameworkiem LangChain.[10] Skwantyzowane warianty (np. 4-bitowe GGUF) modeli o wielkości 7B do 9B parametrów pozwalają na błyskawiczne wnioskowanie nawet na kartach graficznych klasy konsumenckiej (np. NVIDIA z architekturą CUDA), co jest kluczowe dla zachowania wysokiej responsywności aplikacji interaktywnej.[10]

Rygorystyczne Definiowanie i Wywoływanie Narzędzi (Tool Calling)

Aby Agent LLM nie stanowił jedynie interfejsu konwersacyjnego, musi posiadać precyzyjnie zdefiniowany ekosystem narzędzi wywoływanych funkcyjnie (Function Calling/Tool Calling).[5] Modele językowe nie potrafią samodzielnie z wysoką precyzją rozwiązywać całek z mechaniki płynów ani wyciągać pierwiastków w skomplikowanych równaniach termodynamicznych.[14] Ich zadaniem jest pobranie intencji użytkownika, ekstrakcja istotnych wartości brzegowych i wydelegowanie operacji matematycznych do zaufanych podsystemów języka Python.[1]

W ramach proponowanej architektury, ekosystem narzędzi Agenta powinien zostać ustrukturyzowany za pomocą walidatorów schematów (np. biblioteki Pydantic), aby zagwarantować, że przekazywane zmienne są poprawnego typu. Kluczowe narzędzia w tym potoku przedstawiono w poniższej relacji:

Identyfikator Narzędzia (Tool/Function)	Opis Funkcjonalności i Mechanizm	Struktura Wejścia (Input) i Wyjścia (Output)	Rola w Cyfrowym Bliźniaku Egzoplanetarnym

	Działania		
query_nasa_tap_archive	Generuje i wysyła asynchroniczne zapytania SQL za pośrednictwem protokołu Table Access Protocol (TAP) do bazy NASA Exoplanet Archive.[1]	**Wejście:** Nazwa systemu lub parametry filtrujące. **Wyjście:** Ramka danych (Pandas DataFrame) zawierająca m.in. promień (pl_rade), masę, czy strumień naświetlenia.[1]	Eliminuje konieczność ręcznego przeszukiwania katalogów. Agent autonomicznie zasila pipeline rzeczywistymi danymi obserwacyjnymi.[1]
invoke_cgan_imputation	Aktywuje pre-trenowany model CGAN w celu wygenerowania realistycznych rozkładów prawdopodobieństwa dla brakujących lub silnie zaszumionych zmiennych.[1]	**Wejście:** Wektor niekompletnych parametrów. **Wyjście:** Wielowymiarowy tensor zsyntetyzowanych, spójnych fizycznie wariantów planety.[1]	Odbudowuje integralność danych z teleskopów, rozwiązując problem niepełnych pomiarów widmowych lub fotometrycznych.[1]
calculate_habitability_metrics	Uruchamia zoptymalizowane algebraicznie skrypty do ewaluacji matematycznych odległości i prawdopodobieństw, takich jak Indeks Podobieństwa do Ziemi (ESI) czy SEPHI.[1]	**Wejście:** Surowe parametry geofizyczne (masa, promień, temperatura). **Wyjście:** Skalibrowane wskaźniki numeryczne z przypisanymi wagami (np. ESI od 0 do 1).[1]	Przekształca surowe zmienne astronomiczne w ustandaryzowane wymiary filtrujące, niezbędne dla klasyfikatorów.[1]
run_physics_surrog	Komunikuje się z serwerem	**Wejście:** Skompletowany	Błyskawicznie emuluje równania

ate_engine	wnioskowania (Inference Server), przekazując warunki brzegowe do warstwy głębokich sieci neuronowych (PINNFormer/ELM).[1]	wektor stanu. **Wyjście:** Matryce sferyczne temperatur (siatki 2D/3D), profile wiatrów oraz dystrybucja fazowa wody.	różniczkowe GCM, dostarczając dane gotowe do renderowania w interfejsie 3D.[1]

Dzięki architekturze zintegrowanej z LangChain (np. metodzie bind_tools), Agent przyjmuje zapytanie typu "Sprawdź stabilność strefy terminatora dla układu Kepler-186f". LLM formułuje precyzyjne wywołanie do bazy TAP, odbiera dane, przekazuje je do modułu matematycznego w celu weryfikacji blokady pływowej, a następnie aktywuje silnik fizyczny.[5] Gdy wszystkie narzędzia zwrócą wyniki, LLM syntetyzuje skomplikowane matryce numeryczne do formy czytelnej, naukowej konkluzji, opisującej dynamikę atmosferyczną i prawdopodobieństwo przetrwania biosfery.[1] Ta sterylna separacja logiki wnioskowania od silników matematycznych jest absolutnie kluczowym usprawnieniem planu, uniemożliwiającym LLM sztuczne fabrykowanie wyników równań Navier-Stokesa.

Warstwa 2: Rozszerzanie Danych i Przestrzeń Ukryta – Sieci CGAN

Zarządzanie danymi w astrobiologii charakteryzuje się paradoksem: dysponujemy petabajtami odczytów fotometrycznych, z których jedynie ułamek reprezentuje środowiska sprzyjające powstaniu życia. Problem ekstremalnego braku równowagi klasowej (severe class imbalance) stanowi fundamentalną barierę dla klasycznych modeli uczenia maszynowego.[1] Większość algorytmów analitycznych napotykając na dane z teleskopów, gdzie planety zdatne do zamieszkania stanowią margines błędu statystycznego, maksymalizuje swoją predykcję poprzez całkowite ignorowanie klasy mniejszościowej, osiągając sztucznie zawyżoną skuteczność rzędu 99% przy jednoczesnym braku zdolności detekcji autentycznych celów.[1]

Rozwiązaniem zaproponowanym w koncepcji – i stanowiącym genialne posunięcie inżynieryjne – jest wykorzystanie Warunkowych Generatywnych Sieci Przeciwstawnych (Conditional Generative Adversarial Networks - CGAN).[1] Architektura ta dekonstruuje problem poprzez ciągłą rywalizację dwóch głębokich sieci. Sieć generatora przyjmuje losowy szum z przestrzeni ukrytej (latent space) i, warunkowana wektorem klas docelowych (np. poszukiwaniem parametrów planety skalistej w ekosferze), wytwarza syntetyczne sygnatury.[1] Z kolei dyskryminator jest stale trenowany na weryfikacji tych fałszerstw względem rzeczywistych dystrybucji z bazy NASA.[1] W procesie iteracyjnym, generator uczy się z doskonałą precyzją odwzorowywać wielowymiarowe korelacje fizyczne.

Wdrożenie tej warstwy w Cyfrowym Bliźniaku niesie za sobą wielowymiarowe korzyści. CGAN

skutecznie wypełnia pustą przestrzeń wektorową wysoce realistycznymi, syntetycznymi planetami (oversampling), co doprowadza do zbilansowania zbioru treningowego.[1] Pozwala to na wtórne przetrenowanie agresywnych zespołów klasyfikatorów opartych na drzewach decyzyjnych (np. XGBoost), które na tak wzbogaconych danych wykazują precyzję wyodrębniania sygnałów habitabilnych przekraczającą 96% na testach ślepych.[1]

Dodatkowo, dla usprawnienia tej warstwy rekomenduje się wdrożenie paradygmatów bayesowskich do estymacji niepewności (Uncertainty Quantification).[1] W sytuacji, gdy dane obserwacyjne obarczone są potężnym szumem instrumentalnym, bayesowska eksploracja adaptacyjna (Bayesian Adaptive Exploration) traktuje parametry planety jako rozkłady prawdopodobieństwa, a nie wartości punktowe.[1] Aktywna pętla analityczna potrafi zidentyfikować te rejony trzydziestowymiarowej przestrzeni parametrów, w których niepewność predykcyjna systemu jest najwyższa. Dzięki temu system autonomicznie "wie", czego nie wie, informując użytkownika o stopniu zaufania do generowanych wyników, co nadaje projektowi rygor akademicki najwyższej próby.[1]

Warstwa 3: Silnik Fizyczny – Przezwyciężenie Barier przez PINNFormer, ELM oraz Wprowadzenie PI-GAN

Najbardziej kosztownym obliczeniowo aspektem ewaluacji zdatności do zamieszkania jest symulowanie dynamiki klimatu. Klasyczne Modele Ogólnej Cyrkulacji (GCM), rozwiązując fizyczne równania procesów w obrębie drobiazgowych siatek trójwymiarowych, pochłaniają zasoby klastrów obliczeniowych przez tygodnie.[1] Wdrożenie surogatów bazujących na głębokim uczeniu jest niezbędne dla responsywności Cyfrowego Bliźniaka.[1] Zespół trafnie zaproponował wykorzystanie technologii PINNFormer oraz maszyn ELM, które analizujemy i rozszerzamy poniżej.

Sieci Neuronowe Inspirowane Fizyką (PINN) i Ewolucja Transformatorowa (PINNFormer)

Sieci czysto oparte na danych (data-driven) wykazują dramatyczne tendencje do generowania wyników jawnie łamiących zasady termodynamiki podczas prób ekstrapolacji poza wąski zakres danych treningowych.[1] Architektura PINN (Physics-Informed Neural Networks) eliminuje ten kryzys poprzez inkorporację równań różniczkowych cząstkowych (PDE) bezpośrednio do rygoru optymalizacyjnego.[1] Totalna funkcja straty (L_{total}) zostaje wzbogacona o człony karzące algorytm za pogwałcenie zasad zachowania pędu, masy czy energii cieplnej, obliczane za pomocą technik różniczkowania automatycznego (automatic differentiation).[1] Model musi minimalizować wartość resztkową (residual error) rządzących równań (np. dyfuzji ciepła) przy zadanych przestrzennych i czasowych warunkach brzegowych.[1]

Klasyczne PINN opierające się na perceptronach wielowarstwowych (MLP) ulegają jednak

zjawisku błędu spektralnego (spectral bias), błyskawicznie zbiegając do gładkich rozwiązań, przez co całkowicie rozmywają ostre, ekstremalne gradienty temperatur na granicach stref naświetlenia u planet zablokowanych pływowo.[1] Odpowiedzią na tę krytyczną słabość jest **PINNFormer** (Physics-Informed Transformer). Architektura ta wykorzystuje mechanizm wielogłowicowej uwagi (Multi-Head Attention) znany z modeli językowych, aplikując go do danych przestrzenno-czasowych reprezentowanych jako pseudoskwencje.[1] Dzięki temu sieć potrafi w czasie zbliżonym do rzeczywistego korelować oddziaływania atmosferyczne z odległych rejonów globu, idealnie modelując propagację ciepła.[1] Dodatkowo, wdrożenie nowatorskich funkcji aktywacji opartych na falkach (Wavelets) wymusza analizę wysokich częstotliwości, umożliwiając modelowi bezbłędne śledzenie linii terminatora z gigantyczną precyzją rzędu $O(10^{-6})$ błędu, skracając jednocześnie czas zbiegania algorytmu na procesorach graficznych.[1]

Akceleracja Radiacyjna za Pomocą Maszyn Ekstremalnego Uczenia (ELM)

Część zjawisk, takich jak pionowy transfer radiacyjny (emulacja profili absorpcji gazów w atmosferze i emisja promieniowania) cechuje się tak ogromną złożonością wielowymiarową, że nawet transformatory mogą wymagać zbyt długich czasów treningu i inferencji w systemach działających na żywo.[1] W tych specyficznych zadaniach idealnie sprawdzają się **Maszyny Ekstremalnego Uczenia (Extreme Learning Machines - ELM)**.[1]

ELM reprezentuje architekturę bezgradientową. Zamiast iteracyjnej optymalizacji setek warstw za pomocą powolnej wstecznej propagacji błędu (backpropagation), maszyna wykorzystuje zazwyczaj jedną warstwę ukrytą, w której wejściowe wagi i obciążenia są przydzielane losowo i permanentnie zamrożone.[1] Wagi wyjściowe są następnie obliczane analitycznie w pojedynczym, błyskawicznym kroku z wykorzystaniem algebraicznej pseudoodwrotności Moore'a-Penrose'a.[1] Skutkuje to niewyobrażalnym przyspieszeniem: badania transferu radiacyjnego wykazują, że ELM redukuje czas treningu o współczynnik 100 000, zapewniając przy tym 40-krotnie szybsze wnioskowanie predykcyjne w porównaniu do złożonych sieci rekurencyjnych (RNN).[1] Choć pojedynczy węzeł cierpi na degradację przestrzenną przy renderowaniu całego globu, zespoły tych maszyn (Ensemble of ELMs) potrafią natychmiastowo przetwarzać wysokowymiarowe dane tabelaryczne z bezprecedensową efektywnością energetyczną i czasową.[1]

Proponowane Usprawnienie: Physics-Informed GAN (PI-GAN) do Modelowania Zjawisk Stochastycznych

Analiza propozycji użytkownika skłania do zasugerowania głębokiej modyfikacji, która połączy siłę modeli generatywnych z wymogami silnika fizycznego: **Physics-Informed GAN (PI-GAN)**.[22] Podczas gdy PINNFormer świetnie sprawdza się w rozwiązywaniu deterministycznych równań różniczkowych (np. dystrybucji ciepła na idealnej sferze),

planetarne układy klimatyczne są z natury wysoce stochastyczne (chaotyczne formowanie powłoki chmur, turbulencje płynów oceanicznych, uderzenia wiatru słonecznego).

PI-GAN to innowacyjna klasa głębokich modeli generatywnych, która unifikuje trening kontradyktoryjny z prawami fizyki osadzonymi w formie stochastycznych równań różniczkowych (SDEs) wyliczanych przez automatyczne różniczkowanie.[22] W architekturze tej wykorzystuje się zazwyczaj modele oparte na dystansie Wassersteina z karą gradientową (WGAN-GP), co potężnie stabilizuje trening w porównaniu do standardowych sieci GAN.[22] Sieć uczy się rozwiązywania układów odwrotnych i mieszanych na podstawie rzadkich, rozproszonych danych.[22]

Zastąpienie lub uzupełnienie modułu CGAN w potoku warstwą PI-GAN pozwala na jednoczesne powiększanie przestrzeni danych (Data Augmentation) oraz weryfikowanie fizycznej poprawności generowanych próbek. Generator PI-GAN, produkujący syntetyczne profile zachmurzenia czy albedo planetarnego, jest karany przez dyskryminator nie tylko za różnice w statystycznym rozkładzie danych (względem np. wyjść modelu ROCKE-3D), ale również za łamanie podstawowych praw zachowania energii.[23] Taka integracja drastycznie zwiększa wierność cyfrowego bliźniaka, gwarantując generowanie wysokorozdzielczych i spójnych fizycznie map topograficznych, które następnie będą interpretowane przez Agenta LLM.

Inżynieria "Efektu WOW": Trójwymiarowa Oprawa Graficzna i Interaktywność Interfejsu

Zbudowanie rygorystycznego silnika termodynamicznego nie gwarantuje sukcesu w formacie hackathonu, jeśli wyniki nie zostaną zaprezentowane w sposób uderzający wizualnie.[1] Wymóg stworzenia interfejsu z "fajnymi suwaczkami i oprawą graficzną" jest w istocie kluczowym elementem front-endowym Cyfrowego Bliźniaka, odpowiedzialnym za percepcję zaawansowania całego potoku AI. Należy całkowicie odrzucić płaskie wizualizacje numeryczne i proste tabele na rzecz potężnego, responsywnego systemu renderującego w trzech wymiarach.

Architektura Front-End: Streamlit z Integrowanym Silnikiem Plotly

Zalecanym narzędziem do budowy interfejsu (Dashboard) w warunkach ekstremalnego ucisku czasowego jest Pythonowy framework Streamlit, powiązany z zaawansowaną biblioteką renderującą Plotly (plotly.graph_objects).[1] Streamlit natywnie zapewnia płynną obsługę zdarzeń i zarządzanie stanem aplikacji, co jest absolutnie krytyczne, gdy w grę wchodzą setki tysięcy zapytań generowanych przez suwaki.[28]

Prezentacja wygenerowanych przez PI-GAN czy PINNFormer dwuwymiarowych tensorów dystrybucji ciepła (często w wysokiej rozdzielczości, np. 2000x1000 punktów siatki) w postaci płaskiej heatmapy (macierzy pikseli) całkowicie fałszuje proporcje geometryczne biegunów.[29]

Kluczem do uzyskania "Efektu WOW" jest transformacja tych tensorów na układ sferyczny. Procedura ta opiera się na wygenerowaniu ciągłej siatki współrzędnych geograficznych (długość θ w zakresie od 0 do 2π oraz szerokość ϕ od 0 do π) i transformacji ich do trójwymiarowego układu kartezjańskiego za pomocą relacji trygonometrycznych:

$$x = R \cdot \sin(\phi) \cdot \cos(\theta)$$

$$y = R \cdot \sin(\phi) \cdot \sin(\theta)$$

$$z = R \cdot \cos(\phi)$$

Do renderowania tak przygotowanych danych, w środowisku Plotly wykorzystuje się obiekt sferyczny go.Surface.[26] Tradycyjnie obiekt ten mapuje oś Z jako wysokość topograficzną. Głęboką modyfikacją jest wykorzystanie właściwości surfacecolor.[26] Pozwala to na nałożenie wektora wyjściowego z modelu AI (np. rozkładu termodynamicznego lub ułamka pokrywy lodowej) jako gładkiej tekstury oplatającej idealną kulę w przestrzeni wirtualnej.[2] Zastosowanie interpolacji barw (algorytmy wygładzania na przecięciach poligonów) gwarantuje krystalicznie czysty, kinowy efekt końcowy.

Zaawansowane Koloroskalowanie dla Reżimów Klimatycznych

Aby uczynić wizualizację naukowo uzasadnioną i budzącą podziw, standardowe tęczowe skale barw muszą zostać odrzucone.[2] Mapowanie termodynamiczne na obiekcie sferycznym wymaga dyskretnego podejścia definiowanego progami fizycznymi przejść fazowych [2]:

- **Reżim Zlodowacenia ($T < 263\ \mathrm{K}$):** Mapowany rygorystycznie na odcienie świetlistej bieli i głębokiego cyjanu, sygnalizujące uwięzienie wody w fazie stałej oraz potężny efekt albedo.
- **Strefa Ciekłej Wody ($273\ \mathrm{K} < T < 313\ \mathrm{K}$):** Oznaczana nasyconym granatem dla głębokich oceanów. W obszarach o podwyższonym potencjale wymiany gazowej warto zastosować gradienty seledynu, co podświadomie komunikuje oceniającym występowanie obiecującej nisz biosferycznej (np. w stanach "homara").
- **Reżimy Krytyczne i Ekstremalne ($T > 323\ \mathrm{K}$):** Kolory spalonej ziemi – intensywne pomarańcze, czerwień oraz purpura na równiku planet w bliskiej ekosferze, co wizualizuje strefę sterylną i wyparowanie zbiorników wodnych.

Optymalizacja Płynności i State Management

Wielowątkowa manipulacja wykresem 3D zawierającym dziesiątki tysięcy trójkątów siatki wywołuje w technologiach webowych (jak Streamlit) potężne dławienie wydajności, skutkując

opóźnieniami renderowania (tzw. zawieszaniem się aplikacji w stanie "Running...").[34] "Suwaczki" (Sliders), służące do interaktywnej manipulacji takimi wartościami jak masa gwiazdy macierzystej, albedo planety (A), czy natężenie wiatrów, wyzwalają kaskadę procesów wnioskowania.

Utrzymanie natychmiastowej responsywności ("Efektu WOW") wymusza wdrożenie potężnych strategii inżynierii danych:

1. **Agresywne Buforowanie (Caching):** Bezwzględne wykorzystanie dekoratora @st.cache_data dla funkcji inicjujących wagi sieci neuronowych (np. zespołu 50 maszyn ELM) oraz parsowania danych NetCDF/JSON. Zapobiega to przeładowywaniu matryc gigabajtowych podczas każdej zmiany położenia suwaka.[34]
2. **Optymalizacja Serializacji JSON:** Standardowe metody komunikacji między backendem Pythona a frontendem Plotly zawodzą przy ciężkich tensorach sferycznych. Wykorzystanie szybszych bibliotek, takich jak orjson, do obsługi serializacji danych graficznych może radykalnie odciążyć czas przesyłania pakietów do przeglądarki.[34]
3. **Inteligentne Dekodowanie (Throttling / Debouncing):** Interakcje użytkownika z suwakami nie mogą wyzwalać przeliczania równań Navier-Stokesa przez warstwę AI na każdy ułamek zmienionej wartości. System należy zaprojektować tak, by wyzwalał zapytanie do silnika predykcyjnego (PINN/ELM) dopiero po puszczeniu suwaka (trigger "on_change"), podczas gdy w trakcie przesuwania wyświetla się gładka animacja przejścia (CSS) lub prekompilowany wektor przybliżenia.

Taka integracja płynnie animowanej, poddającej się pełnej interakcji kuli 3D wraz z okienkiem tekstowym, w którym Agent LLM w czasie rzeczywistym loguje swoje analityczne wnioski (łańcuch myślowy: "Zmiana albedo do 0.4 na skutek kondensacji chmur wywołała gwałtowny spadek OHT; symulacja wykazuje wejście planety w globalne zlodowacenie..."), gwarantuje prezentację bezkonkurencyjną na tle rywali tworzących statyczne wykresy.

Proponowane Modyfikacje Architektoniczne i Strategia Wdrożenia (Hackathon Execution)

Koncepcja połączenia LLM, CGAN oraz PINNFormer/ELM jest fundamentalnie genialna. Z technicznego punktu widzenia stanowi ona tzw. Hybrid SciML (Scientific Machine Learning) Framework.[1] Jednak próba zakodowania wszystkich tych elementów od absolutnego zera w trakcie 72-godzinnego wydarzenia takiego jak HACK-4-SAGES wiąże się ze śmiertelnym ryzkiem (tzw. "overengineering"), który najczęściej kończy się prezentacją niedziałającego, zbugowanego kodu.[1] Aby zapewnić 100% pewności, że produkt na koniec dowiezie oszałamiający efekt wizualny i zademonstruje głębię analityczną, konieczne są bezkompromisowe modyfikacje oraz precyzyjny podział fazowy.

Przejście od Wymuszonego Treningu do Surogatów Wstępnych

(Pre-trained Surrogates)

Najpoważniejszym zagrożeniem jest czas zbiegania sieci neuronowych. Wymuszenie na architekturze PINNFormer poszukiwania rozwiązania dla nieliniowych równań dyfuzji ciepła z użyciem optymalizatorów w czasie rzeczywistym całkowicie sparaliżuje interfejs aplikacji (opóźnienia rzędu wielu godzin).[1]

Rekomendowana zmiana: Cyfrowy bliźniak na etapie hackathonu nie powinien trenować się "na żywo". Zadaniem inżynierów Data Science w pierwszych 24 godzinach jest asynchroniczne przetworzenie dostępnych zrzutów z publicznych repozytoriów modeli NASA ROCKE-3D (pliki NetCDF) o rozdzielczości siatki 4x5 stopni przestrzennych.[1] Na ich podstawie uczy się zamrożonych, bezgradientowych zespołów maszyn ELM (które optymalizują się natychmiast) oraz lekkiej wersji PI-GAN do generacji powłoki chmur.[1] Pobrane i zapamiętane wagi modelu stają się silnikiem wnioskowania błyskawicznego. Agent LLM podaje wyłącznie warunki graniczne (temperatura gwiazdy, kąt), a system wykonuje jedną milisekundową iterację predykcyjną.

Poskromienie Halucynacji Agenta poprzez Kontrolowane Pętle ReAct

System LLM obdarzony narzędziami, mimo swoich potężnych możliwości rozumowania w architekturze ReAct (Reason-Act), może łatwo wpaść w pętlę generowania urojonych hipotez chemicznych i astrofizycznych, ignorując twarde wyniki silnika matematycznego.[1]

Rekomendowana zmiana: Wdrożenie ścisłych plików gramatycznych (Grammar Files) nakładających kagańce na formaty zwracane przez Agenta.[17] Oznacza to implementację Pydantic dla obiektów zwracanych w LangChain. LLM musi mieć fizycznie odebraną możliwość generowania wymyślonych sygnatur widmowych; jego rola zostaje zredukowana do wyciągania celów z bazy query_nasa_tap_archive (np. filtracja SQL dla $R_{pl} < 2R_{\oplus}$ i dyspozycji 'Confirmed' [15]), aktywacji silników matematycznych i *wyłącznie* translacji otrzymanego wektora temperatur i frakcji zdatności z powrotem na gładki język naukowy w oknie chatu. Agent "kieruje ruchem", ale jest zablokowany z dostępu do modyfikowania fizycznych macierzy.[1]

Architektura Oparta na Sferycznym Pipeline Zdarzeń (Event-Driven Pipeline)

Ostateczny kształt architektury, gwarantujący mistrzowskie parametry działania, przyjmuje postać wielowarstwowej rury przesyłowej (Event-Driven Pipeline):

1. **Warstwa UI (Streamlit):** Odbiera tekstowe żądanie od sędziego (lub pobiera z suwaków modyfikatory). Renderuje animowaną sferę 3D za pomocą optymalizowanego Plotly i buforowanych bibliotek mapowania.
2. **Warstwa Orkiestracji (AstroLLaMA zdefiniowana przez LangChain):** Parsuje prośbę,

tworzy zapytanie TAP SQL, komunikuje się w tle asynchronicznie z archiwum NASA i kompletuje wektor zjawisk.

3. **Warstwa Korekcji Danych (CGAN):** Imputuje brakujące przestrzenie (np. niepewności w dystansie krzywych tranzytowych), zwalczając błędy odczytu i zapewniając idealnie symetryczne, fizycznie spójne pakiety danych wejściowych.
4. **Silnik Obliczeniowy (Ensemble ELM + PI-GAN / PINNFormer):** Błyskawicznie rozwiązuje ujęcie stochastyczne i deterministyczne klimatu planety, zwracając w ułamku sekundy gotową macierz temperatur (uwzględniającą zjawiska "Lobster/Eyeball state" i OHT) bezpośrednio na zniekształconą teksturę kuli.
5. **Warstwa Narracyjna (LLM Synthesizer):** Wypluwa ciągłe, głębokie i analityczne wnioski na żywo, komentując np. dlaczego symulacja weszła w sprzężenie zwrotne lód-albedo.

Tak zaprojektowana i zorkiestrowana architektura wykracza poza ramy jakiegokolwiek studenckiego projektu prototypowego. Jest ona implementacją profesjonalnego standardu narzędzi instytutowych, łącząc rygorystyczne ramy matematycznej fizyki równań cząstkowych, potęgę głębokich sieci dyskryminatywnych (CGAN) i nieskrępowaną inteligencję komunikacyjną specjalistycznych LLM. Zastosowanie przedstawionych w raporcie mechanizmów optymalizacyjnych, takich jak maszyny bezgradientowe (ELM) oraz precyzyjne interfejsy sferyczne, unieważnia ryzyko paraliżu sprzętowego i dostarcza platformę o gigantycznym potencjale innowacyjnym i edukacyjnym, gwarantującą zdeklasowanie konwencjonalnych projektów na hackathonie z pogranicza sztucznej inteligencji.

Cytowane prace

1. Hackathon_ Egzoplanety i AI.pdf
2. Applying full color image texture to create an interactive earth globe - Plotly Python, otwierano: lutego 22, 2026, https://community.plotly.com/t/applying-full-color-image-texture-to-create-an-interactive-earth-globe/60166
3. Role of ocean heat transport in climates of tidally locked exoplanets around M dwarf stars, otwierano: lutego 22, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC3896211/
4. Lobster-Shaped Extrasolar Oceans - Astrobiology Web, otwierano: lutego 22, 2026, https://astrobiology.com/2014/03/lobster-shaped-extrasolar-oceans.html
5. Workflows and agents - Docs by LangChain, otwierano: lutego 22, 2026, https://docs.langchain.com/oss/python/langgraph/workflows-agents
6. AstroLLaMA: Towards Specialized Foundation Models in Astronomy - ACL Anthology, otwierano: lutego 22, 2026, https://aclanthology.org/2023.wiesp-1.7.pdf
7. AstroMLab/astrollama-2-7b-chat_aic - Hugging Face, otwierano: lutego 22, 2026, https://huggingface.co/AstroMLab/astrollama-2-7b-chat_aic
8. AstroMLab/astrollama-3-8b-base_aic - Hugging Face, otwierano: lutego 22, 2026, https://huggingface.co/AstroMLab/astrollama-3-8b-base_aic
9. [Paper] AstroLLaMA: Towards Specialized Foundation Models in Astronomy -

Community, otwierano: lutego 22, 2026, https://community.openai.com/t/paper-astrollama-towards-specialized-foundation-models-in-astronomy/375667
10. LangChain Ollama Integration: Complete Tutorial with Examples - Latenode, otwierano: lutego 22, 2026, https://latenode.com/blog/ai-frameworks-technical-infrastructure/langchain-setup-tools-agents-memory/langchain-ollama-integration-complete-tutorial-with-examples
11. How to Build a Local AI Agent With Python (Ollama, LangChain & RAG) - YouTube, otwierano: lutego 22, 2026, https://www.youtube.com/watch?v=E4I91XKQSgw
12. How to Build AI Chatbots with Mistral and Llama2 - Anaconda, otwierano: lutego 22, 2026, https://www.anaconda.com/blog/how-to-build-ai-chatbots-with-mistral-and-llama2
13. Tool Calling with LangChain, otwierano: lutego 22, 2026, https://blog.langchain.com/tool-calling-with-langchain/
14. Tool calling - Llama API, otwierano: lutego 22, 2026, https://llama.developer.meta.com/docs/guides/tool-guide
15. Retrieving Exoplanet Archive Data With Table Access Protocol, otwierano: lutego 22, 2026, https://exoplanetarchive.ipac.caltech.edu/docs/TAP/usingTAP.html
16. Using the Application Programming Interface (API) - NASA Exoplanet Archive - Caltech, otwierano: lutego 22, 2026, https://exoplanetarchive.ipac.caltech.edu/docs/program_interfaces.html
17. Developing Concepts of Operations Using Multi-Step Tool Techniques with Large Language Models, otwierano: lutego 22, 2026, https://ntrs.nasa.gov/api/citations/20240011037/downloads/ai4se_2024_v2.pdf
18. Paper page - PINNsFormer: A Transformer-Based Framework For ..., otwierano: lutego 22, 2026, https://huggingface.co/papers/2307.11833
19. PINNsFormer: A Transformer-Based Framework For Physics-Informed Neural Networks, otwierano: lutego 22, 2026, https://arxiv.org/html/2307.11833v3
20. Extreme learning machines for exoplanet simulations: a faster, lightweight alternative to deep learning | RAS Techniques and Instruments | Oxford Academic, otwierano: lutego 22, 2026, https://academic.oup.com/rasti/article/doi/10.1093/rasti/rzaf050/8305079
21. Extreme Learning Machines for Exoplanet Simulations: A Faster, Lightweight Alternative to Deep Learning - ResearchGate, otwierano: lutego 22, 2026, https://www.researchgate.net/publication/392980074_Extreme_Learning_Machines_for_Exoplanet_Simulations_A_Faster_Lightweight_Alternative_to_Deep_Learning
22. Physics-Informed Generative Adversarial Networks for Stochastic Differential Equations | SIAM Journal on Scientific Computing, otwierano: lutego 22, 2026, https://epubs.siam.org/doi/10.1137/18M1225409
23. Physics-Informed GANs - Emergent Mind, otwierano: lutego 22, 2026, https://www.emergentmind.com/topics/physics-informed-generative-adversarial-networks-pi-gans

24. A Physics-Informed GAN Framework for Modeling Spatiotemporal Correlated Temperature Field During Grain Storage - IEEE Xplore, otwierano: lutego 22, 2026, https://ieeexplore.ieee.org/document/11163994/
25. Physics-Informed Generative Adversarial Network-Based Modeling and Simulation of Linear Electric Machines - MDPI, otwierano: lutego 22, 2026, https://www.mdpi.com/2076-3417/12/20/10426
26. 3d surface plots in Python, otwierano: lutego 22, 2026, https://plotly.com/python/3d-surface-plots/
27. Create Heatmaps using graph_objects class in Plotly - GeeksforGeeks, otwierano: lutego 22, 2026, https://www.geeksforgeeks.org/python/create-heatmaps-using-graph_objects-class-in-plotly/
28. Creating Your First Streamlit Heatmap | by whyamit404 - Medium, otwierano: lutego 22, 2026, https://medium.com/@whyamit404/creating-your-first-streamlit-heatmap-6d1ec844431e
29. Plotly and Python: Creating Interactive Heatmaps for Petrophysical & Geological Data, otwierano: lutego 22, 2026, https://towardsdatascience.com/plotly-and-python-creating-interactive-heatmaps-for-petrophysical-geological-data-701c22b32e4/
30. Heatmaps in Python - Plotly, otwierano: lutego 22, 2026, https://plotly.com/python/heatmaps/
31. Heatmap is slow for large data arrays - Plotly Community Forum, otwierano: lutego 22, 2026, https://community.plotly.com/t/heatmap-is-slow-for-large-data-arrays/21007
32. Surface plot on a globe plot - Plotly Python - Plotly Community Forum, otwierano: lutego 22, 2026, https://community.plotly.com/t/surface-plot-on-a-globe-plot/34101
33. Applying full color image texture to create an interactive earth globe - #6 by empet, otwierano: lutego 22, 2026, https://community.plotly.com/t/applying-full-color-image-texture-to-create-an-interactive-earth-globe/60166/6
34. Plotly Performance Issues Despite Caching - Using Streamlit, otwierano: lutego 22, 2026, https://discuss.streamlit.io/t/plotly-performance-issues-despite-caching/110491
35. Slow and instable app when using plotly charts - Using Streamlit, otwierano: lutego 22, 2026, https://discuss.streamlit.io/t/slow-and-instable-app-when-using-plotly-charts/50808
36. How to render chart faster - Using Streamlit, otwierano: lutego 22, 2026, https://discuss.streamlit.io/t/how-to-render-chart-faster/6237
37. Optimize Streamlit Deployment - Towards Data Science, otwierano: lutego 22, 2026, https://towardsdatascience.com/optimize-streamlit-deployment-1b9bb0e415b/
38. BaratiLab/PhysicsInformedTokenTransformer: Official repository for Physics

Informed Token Transformer (PITT) - GitHub, otwierano: lutego 22, 2026, https://github.com/BaratiLab/PhysicsInformedTokenTransformer