Strategiczne Koncepcje Cyfrowych Bliźniaków Egzoplanetarnych: Zaawansowane Architektury Uczenia Maszynowego w Astrobiologii Obliczeniowej

1. Wprowadzenie do Precyzyjnej Egzoklimatologii i Paradygmatu Cyfrowych Bliźniaków

Przejście od czysto obserwacyjnej astronomii do predykcyjnej egzoklimatologii stanowi jedną z najgłębszych zmian paradygmatu we współczesnej astrofizyce.[1] Historycznie, poszukiwania egzoplanet były zdominowane przez statystyczną akumulację odkryć, mającą na celu odpowiedź na pytanie, czy ciała planetarne poza Układem Słonecznym istnieją w znaczących liczbach. Wraz z misjami takimi jak Kepler, Transiting Exoplanet Survey Satellite (TESS) oraz Kosmicznym Teleskopem Jamesa Webba (JWST), działającymi z niespotykaną dotąd rozdzielczością, dyscyplina ta ewoluowała w kierunku szczegółowej charakteryzacji tych odległych światów.[1] W konsekwencji, współczesna astrobiologia staje przed potężnym wyzwaniem analitycznym: zidentyfikowaniem, które z tysięcy potwierdzonych egzoplanet posiadają odpowiednie warunki fizyczne, atmosferyczne i klimatyczne do podtrzymania życia.[1]

Aby sprostać ogromnej objętości i wielowymiarowości tych danych, środowisko naukowe coraz częściej opiera się na koncepcji „cyfrowego bliźniaka" (digital twin). Cyfrowy bliźniak w kontekście nauk planetarnych to wysoce wyrafinowana, stale aktualizowana wirtualna replika układu fizycznego.[1] Pozwala ona na przeprowadzanie symulacji i modyfikowanie warunków brzegowych w celu obserwacji, jak klimat egzoplanety, transport ciepła w oceanach czy chemia atmosferyczna mogą ewoluować w geologicznych skalach czasowych.[1] Dla oceny zdatności egzoplanet do zamieszkania (habitability), konstruowanie takich cyfrowych bliźniaków wymaga syntezy mechaniki orbitalnej, modeli irradiancji gwiazdowej oraz dynamiki płynów, co tradycyjnie realizowane jest poprzez obliczeniowo kosztowne Modele Ogólnej Cyrkulacji (GCM - General Circulation Models).[1]

Jednakże przepuszczenie pojedynczej konfiguracji planetarnej przez klasyczny trójwymiarowy model GCM, taki jak ROCKE-3D, może wymagać tysięcy godzin obliczeniowych, co czyni niemożliwym przeprowadzanie zakrojonych na szeroką skalę analiz parametrów przestrzeni kosmicznej.[1] Integracja sztucznej inteligencji (AI) i architektur uczenia maszynowego (ML) dostarcza głębokiego rozwiązania tego obliczeniowego wąskiego gardła.[1] Poprzez zastąpienie

lub wsparcie tradycyjnych solverów opartych na fizyce emulatorami uczenia maszynowego, możliwe jest uzyskanie prognoz rozkładu temperatur planetarnych, widm atmosferycznych oraz wskaźników zdatności do zamieszkania przy ułamku tradycyjnych kosztów obliczeniowych.[1]

Niniejszy raport stanowi wyczerpującą analizę teoretyczną i architektoniczną, zaprojektowaną pod kątem zaawansowanych inicjatyw obliczeniowych, ze szczególnym uwzględnieniem hackathonów naukowych, takich jak HACK-4-SAGES (Kategoria 3: Cyfrowe Bliźniaki w Zdatności Egzoplanet do Zamieszkania).[1] Analiza ta nakreśla teoretyczną astrofizykę leżącą u podstaw klimatów planetarnych, ocenia najbardziej efektywne architektury neuronowe do emulacji, analizuje strukturę dostępnych astronomicznych baz danych oraz proponuje rygorystyczne, innowacyjne i możliwe do wdrożenia w krótkim czasie koncepcje projektowe.[1] Przestrzeń przecięcia równań różniczkowych, statystyki i głębokiego uczenia stanowi idealną domenę do szybkiego, wysokowpływowego rozwoju algorytmicznego dla interdyscyplinarnych zespołów programistycznych.[1]

2. Teoretyczne Podstawy Astrofizyki i Dynamiki Klimatu

Aby skutecznie trenować modele uczenia maszynowego dla egzoplanetarnych cyfrowych bliźniaków, należy najpierw ustalić podstawowe mechaniki fizyczne dyktujące klimaty egzoplanetarne.[1] Model uczenia maszynowego jest tylko tak solidny, jak matematyczna fizyka, którą próbuje emulować; zatem głębokie zrozumienie tych planetarnych równań jest warunkiem wstępnym dla inżynierii cech (feature engineering) i formułowania modelu.[1] Zrozumienie relacji między gwiazdą a planetą determinuje wszystkie późniejsze kroki symulacyjne.

2.1 Ekosfera i Temperatura Równowagowa

Fundamentalną metryką zdatności do zamieszkania jest teoretyczna zdolność planety do utrzymania ciekłej wody na swojej powierzchni, co potocznie określa się mianem Ekosfery (Habitable Zone - HZ).[1] Chociaż klasyczne definicje HZ są nadmiernie uproszczone, pozostają one niezbędnym punktem odniesienia (baseline) do filtrowania ogromnych zestawów danych astronomicznych.[1] Głównym wskaźnikiem warunków panujących na powierzchni planety jest jej temperatura równowagowa, przy założeniu równomiernej redystrybucji ciepła. Temperatura ta, oznaczana jako T_{eq}, wyprowadzana jest z prawa Stefana-Boltzmanna i definiowana matematycznie jako:

$$T_{eq} = \left(\frac{S(1-A)}{4\sigma} \right)^{1/4}$$

gdzie S reprezentuje padający strumień promieniowania gwiazdowego (insolation flux), A reprezentuje planetarne albedo Bonda (ułamek energii elektromagnetycznej odbijanej z powrotem w przestrzeń kosmiczną), a σ to stała Stefana-Boltzmanna.[1] Chociaż to równanie dostarcza wyidealizowanej linii bazowej, rzeczywiste temperatury powierzchniowe są silnie modulowane przez efekt cieplarniany, gęstość atmosferyczną oraz wzorce cyrkulacji.[1] Dla gwiazd różnych typów widmowych, w szczególności czerwonych karłów (typu M), które są niezwykle powszechne i często goszczą planety typu ziemskiego, granice Ekosfery są wysoce wrażliwe na efektywną temperaturę gwiazdy.[1] Zaawansowane modele empiryczne wykorzystują równania wielomianowe do precyzyjnego definiowania tych granic, uwzględniając takie zjawiska jak niekontrolowany efekt cieplarniany (runaway greenhouse effect) na wewnętrznej krawędzi oraz maksymalny limit cieplarniany dwutlenku węgla na krawędzi zewnętrznej.[1]

2.2 Mechanika Orbitalna i Dynamika Zablokowania Pływowego

Kluczową kwestią dla współczesnej egzoklimatologii jest zjawisko zablokowania pływowego (tidal locking).[1] Ponieważ gwiazdy o małej masie, w szczególności karły typu M, emitują znacznie mniej energii świetlnej niż gwiazdy typu G (takie jak Słońce), ich odpowiednie ekosfery znajdują się znacznie bliżej gwiazdy.[1] Planety krążące w tych bliskich ekosferach poddawane są intensywnym gradientom grawitacyjnym wzdłuż swoich średnic.[1] Przez miliony lat, dyssypacja pływowa zmusza okres rotacji planety do synchronizacji z jej okresem orbitalnym.[1] W rezultacie planeta jest zwrócona zawsze tą samą półkulą do gwiazdy, doświadczając wiecznego dnia, podczas gdy przeciwna półkula pozostaje w wiecznej ciemności.[1]

Matematyczne ramy rządzące ewolucją stanu rotacji planety w kierunku rotacji synchronicznej są wysoce złożone.[1] Stan rotacji jest śledzony przy użyciu długości podgwiezdnej, oznaczanej jako γ, która reprezentuje kąt między długą osią planety a stacjonarną linią inercjalną względem anomalii średniej.[1] Równanie ruchu dla rotacji planety pod wpływem sił pływowych uwzględnia czynnik zależny od ekscentryczności oraz czynnik trójosiowości głównych momentów bezwładności. Aby określić tempo, w jakim stan rotacji zwalnia do stanu zablokowanego, modele uwzględniają stałą dyssypację pływową opóźnienia czasowego, rządzoną równaniem różniczkowym:

$$\ddot{\gamma} + \frac{1}{2}\omega_s^2 \sin(2\gamma) + \ddot{n} + \epsilon\dot{\gamma} = 0$$

gdzie stała ϵ konsoliduje kilka parametrów fizycznych, w tym masę gwiazdy, masę planety, promień planety, półoś wielką orbity oraz parametr pływowy Q.[1] Parametr pływowy drastycznie różni się w zależności od kompozycji planety; wartość Q równa 10 jest typowo

stosowana dla planet z grubymi atmosferami lub globalnymi oceanami, podczas gdy wartość 100 jest stosowana dla światów pokrytych lądolodami.[1]

Alternatywnie, skalę czasową wymaganą do osiągnięcia przez planetę zablokowania pływowego można oszacować przy użyciu uproszczonego fizycznego przybliżenia:

$$t_{lock} \approx \frac{\omega a^6 IQ}{3GM_p^2 k_2 R_p^5}$$

Zależnie od specyficznych parametryzacji, czas ten często można przybliżyć funkcją postaci $t_{lock} \approx 1486(a^{0.027} M^{1/3})^6$ (gdzie a to dystans w centymetrach, a M masa gwiazdy), co pozwala stwierdzić, czy dana planeta wpadła już w rezonans synchroniczny.[1] Zrozumienie tego stanu jest absolutnie kluczowe, ponieważ wolno rotująca planeta doświadcza sił Coriolisa, które fundamentalnie zmieniają globalną cyrkulację atmosferyczną, podczas gdy planeta zablokowana pływowo opiera się całkowicie na dywergencji substelarnej (różnicy między dniem a nocą) w celu transportu ciepła.[1]

2.3 Cyrkulacja Atmosferyczna i Oceaniczny Transport Ciepła

Założenie, że dzienna strona planety zablokowanej pływowo ugotowałaby się, podczas gdy nocna zamarzła, ignoruje głęboki wpływ płynów atmosferycznych i oceanicznych (fluid dynamics).[1] W rzeczywistości, gęsta atmosfera lub globalny ocean będą transportować energię termiczną z napromieniowanej strony dziennej na ciemną stronę nocną, radykalnie zmieniając rozkład temperatury na powierzchni planety.[1]

Sprzężenia zwrotne klimatu odgrywają dyktatorską rolę w tej dystrybucji energii.[1] Sprzężenie zwrotne lód-albedo to prominentna pozytywna pętla sprzężenia zwrotnego, gdzie ochłodzenie prowadzi do zwiększonego tworzenia się lodu; ponieważ lód posiada wysokie albedo, odbija więcej światła gwiazdy, prowadząc do dalszego ochłodzenia i potencjalnego globalnego zlodowacenia.[1] Odwrotnie, cykl węglanowo-krzemianowy działa jako negatywne, stabilizujące sprzężenie zwrotne w geologicznych skalach czasowych poprzez sekwestrację lub uwalnianie dwutlenku węgla w odpowiedzi na wahania temperatury.[1]

Kiedy globalne oceany zostają wprowadzone do modelu planetarnego, transport ciepła staje się wysoce zlokalizowany.[1] Wysokorozdzielcze badania 3D GCM wykazały, że zablokowane pływowo akwaplanety wykazują odrębne stany klimatyczne na podstawie wydajności Oceanicznego Transportu Ciepła (OHT - Ocean Heat Transport).[1] Planeta z bardzo słabym OHT wejdzie w stan „gałki ocznej" (eyeball state), charakteryzujący się okrągłym obszarem ciekłej wody dokładnie w punkcie podgwiezdnym, otoczonym globalną skorupą grubego lodu morskiego.[1] Jednakże, gdy OHT jest wysoce wydajne, prądy równikowe transportują ciepło na wschód, topiąc lód i skutkując stanem „homara" (lobster state) – konfiguracją charakteryzującą się ogromnym, wydłużonym oceanem równikowym, który znacznie powiększa obszar

powierzchni zdatny do zamieszkania.[1] Symulowanie tych przejść fazowych i przepływów termodynamicznych wymaga rozwiązywania równań Naviera-Stokesa oraz równań termodynamicznego transportu energii na sferycznej siatce, co jest przedsięwzięciem idealnie nadającym się do akceleracji poprzez głębokie uczenie.[1]

2.4 Aktywność Gwiazdowa i Erozja Atmosferyczna

Poza równowagą termiczną, zdatność do zamieszkania planet krążących wokół czerwonych karłów (M-dwarfs) jest poważnie zagrożona przez kosmiczną pogodę i aktywność gwiazdową.[1] Czerwone karły są notorycznie aktywne, często emitując potężne rozbłyski gwiazdowe (stellar flares) charakteryzujące się intensywnym promieniowaniem rentgenowskim i skrajnie dalekim ultrafioletem (XUV), którym często towarzyszą koronalne wyrzuty masy (CME).[1]

Kiedy planeta o rozmiarach ziemskich zostanie poddana ogromnemu strumieniowi XUV, górna warstwa atmosfery (termosfera) ulega gwałtownemu nagrzaniu i jonizacji.[9] Ta ekspansja termiczna drastycznie powiększa egzobazę planetarną, wypychając gazy atmosferyczne poza granicę Roche'a, gdzie są one zdmuchiwane przez wiatry gwiazdowe.[9] Ten proces, znany jako ucieczka hydrodynamiczna (hydrodynamic escape), może doprowadzić do wyerodowania atmosfery podobnej do ziemskiej i całkowitego wysuszenia oceanów planetarnych w ciągu zaledwie kilkuset milionów lat.[1] Ponadto wysokoenergetyczne zdarzenia protonowe związane z rozbłyskami katalizują niszczenie ozonu atmosferycznego, usuwając pierwotną osłonę przed biologicznymi uszkodzeniami UV.[8] W związku z tym, analiza dystrybucji częstotliwości rozbłysków (FFD - Flare Frequency Distribution) gwiazd macierzystych jest obowiązkowym krokiem w potwierdzaniu długoterminowej zdatności egzoplanet do zamieszkania.[1] Zjawiska te wymuszają stworzenie modeli zdolnych ewaluować nie tylko samą pozycję geometryczną planety, lecz także czas retencji jej atmosfery w obliczu kosmicznej radiacji.

3. Matematyczne Metryki Klasyfikacji i Zdatności do Zamieszkania

Tradycyjne podejście astrofizyki definiowało ekosferę w sposób zero-jedynkowy (binarny). W kontekście nowoczesnego uczenia maszynowego konieczne jest jednak przekształcenie tej koncepcji w ciągłą funkcję produkcji, która jest w stanie przyjmować parametry geofizyczne i oceniać prawdopodobieństwo zdatności planety do utrzymania biosfery. Istniejące metryki stanowią fundament dla zaawansowanych pipeline'ów AI.

3.1 Indeks Podobieństwa do Ziemi (Earth Similarity Index - ESI)

Indeks Podobieństwa do Ziemi (ESI) to wiodąca wieloparametrowa metryka dystansowa służąca do oceny fizycznego podobieństwa egzoplanety do Ziemi, skalująca się w zakresie od 0 do 1, gdzie 1 reprezentuje identyczny odpowiednik naszej planety.[1] ESI nie jest bezpośrednią miarą habitability, lecz narzędziem filtrującym w ogromnych katalogach.[12] Jest matematycznie

podzielony na Wewnętrzne ESI (Interior ESI) oraz Powierzchniowe ESI (Surface ESI).[1] Fundamentalne obliczenie dla dowolnej pojedynczej właściwości wykorzystuje zważoną formułę bazującą na odległościach:

$$ESI_i = \left(1 - \left|\frac{x_i - x_{i,0}}{x_i + x_{i,0}}\right|\right)^{w_i}$$

gdzie x_i jest zmierzonym parametrem egzoplanety, $x_{i,0}$ jest ziemską wartością referencyjną, a w_i jest specyficznym wykładnikiem wagowym dla tej właściwości.[1] Ponieważ skala jest wysoce wrażliwa na zmiany stanu termodynamicznego wód, temperatura powierzchniowa otrzymuje w obliczeniach najwyższy wykładnik wagowy.[1]

W tabeli 1 przedstawiono zoptymalizowany podział parametrów fizycznych wykorzystywanych do klasyfikacji:

Właściwość Planetarna	**Subkategoria ESI**	**Ziemska Wartość Referencyjna (xi,0)**	**Wykładnik Wagowy (wi)**	**Fizyczne Znaczenie dla Biosfery**
Średni Promień (Mean Radius)	Interior	1.0 Promienia Ziemi	0.57	Determinuje siłę grawitacji i pojemność retencyjną atmosfery. [1]
Gęstość Objętościowa (Bulk Density)	Interior	1.0 Gęstości Ziemi	1.07	Wskazuje na skalistą (terrestrial) kompozycję względem gazowej otoczki. [1]
Prędkość Ucieczki (Escape Velocity)	Surface	1.0 Ziemskiej Jednostki	0.70	Dyktuje stabilność atmosfery przeciwko ucieczce hydrodynamic

				znej i wiatrom słonecznym. [1]
Temperatura Powierzchni	Surface	288.0 Kelwinów	5.58	Najwyżej ważony parametr; krytyczna bariera dla istnienia ciekłej wody. [1]

3.2 Wskaźnik Statystycznego Prawdopodobieństwa Zdatności (SEPHI)

Podczas gdy ESI ocenia wyłącznie fizyczne podobieństwo, Statistical-likelihood Exo-Planetary Habitability Index (SEPHI) opiera się na prawdopodobieństwie oszacowania potencjału.[14] Model SEPHI weryfikuje cztery kryteria, które transformowane są w funkcje wiarygodności (likelihood functions) powiązane z fizycznymi procesami [13]:

1. Czy planeta posiada strukturę telluryczną? [14]
2. Czy ma odpowiednią gęstość atmosfery i uwarunkowania grawitacyjne? [14]
3. Czy występuje stabilność termodynamiczna ciekłej wody? [14]
4. Czy posiada pole magnetyczne wystarczające do ochrony przed zabójczą radiacją? [14]

Wartość indeksu definiowana jest jako średnia geometryczna czterech podindeksów:

$$SEPHI = \left(\prod_{i=1}^{4} L_i\right)^{1/4}$$

gdzie każda wartość L_i jest znormalizowana.[13] Użycie średniej geometrycznej eliminuje sztuczne, arbitralne wagi - brak spełnienia jednego z fundamentalnych kryteriów (np. całkowity brak pola magnetycznego przy gwałtownym czerwonym karle) drastycznie redukuje całkowite prawdopodobieństwo istnienia życia, co naśladuje naturalne bariery biologiczne.[13] Metryka ta idealnie mapuje problem jako optymalizację rozkładu prawdopodobieństwa.

3.3 Indeks Zdatności dla Planet Tranzytowych (HITE)

Dla misji analizujących zmienność fotometryczną (tranzyty), takich jak Kepler czy TESS, implementowany jest wskaźnik Habitability Index for Transiting Exoplanets (HITE).[5] Zamiast zakładać istnienie idealnych uwarunkowań na podstawie samej odległości, HITE przetwarza głębokości tranzytu (transit depth), okres (period) oraz ułamkową obecność promieniowania gwiazdy. Pozwala on zredukować błąd fałszywych detekcji zwany "degeneracją ekscentryczności-albedo" (eccentricity-albedo degeneracy), poprzez matematyczne nałożenie kar (penalties) na planety o zbyt dużych promieniach, co eliminuje minineptuny i gorące jowisze

na rzecz potencjalnie skalistych obiektów.[5]

4. Zaawansowane Architektury Uczenia Maszynowego w Astrobiologii

Zastosowanie uczenia maszynowego w naukach planetarnych wykracza daleko poza proste dopasowywanie danych (data fitting); wymaga starannego doboru architektur zdolnych do respektowania praw fizyki przy jednoczesnej interpolacji w wysokowymiarowych przestrzeniach parametrów.[1] W środowiskach szybkiego programowania, jak np. podczas 72-godzinnych hackathonów, wybór prawidłowego algorytmu decyduje o tym, czy wirtualny bliźniak zbiegnie się do funkcjonalnego prototypu w czasie rzeczywistym, czy ulegnie załamaniu pod wpływem obciążeń obliczeniowych.[1]

4.1 Sieci Neuronowe Inspirowane Fizyką (Physics-Informed Neural Networks - PINNs)

Czysto oparte na danych (data-driven) modele uczenia maszynowego są fundamentalnie obojętne na prawa fizyki rządzące wszechświatem.[1] W konsekwencji, gdy oczekuje się od nich przewidzenia temperatur na powierzchniach planet poza specyficznym rozkładem ich danych treningowych (np. dla unikalnego układu TRAPPIST-1), często generują wyniki fizycznie niemożliwe (jak pogwałcenie zasad termodynamiki).[1] Sieci PINN rozwiązują ten problem bezpośrednio osadzając równania różniczkowe cząstkowe (PDE) w funkcji straty (loss function) sieci neuronowej.[1]

W standardowej sieci neuronowej celem jest zminimalizowanie błędu średniokwadratowego (MSE) między przewidywaniami a danymi empirycznymi.[1] W architekturze PINN, funkcja straty jest rozbudowana w celu nałożenia kar (penalties) na sieć za naruszenie praw zachowania pędu, masy czy energii cieplnej.[1] Całkowita funkcja straty dla sieci PINN symulującej klimat konstruowana jest następująco:

$$L_{total} = \lambda_{data} L_{data} + \lambda_{PDE} L_{PDE} + \lambda_{BC} L_{BC} + \lambda_{IC} L_{IC}$$

gdzie L_{data} to błąd względem znanych danych obserwacyjnych, L_{PDE} to wartość resztkowa (residual error) rządzących równań różniczkowych (np. równania dyfuzji ciepła, rozwiązanego na siatce sferycznej) obliczona za pomocą rygorystycznego różniczkowania automatycznego (automatic differentiation), L_{BC} narzuca przestrzenne warunki brzegowe (takie jak promieniowanie podgwiezdne padające pod odpowiednim kątem), a L_{IC} kontroluje stany początkowe.[1] Dynamicznie dopasowywane parametry wagowe λ zapewniają poprawne zbieganie.[1] Sieci PINN, wykorzystujące np. bibliotekę Python o nazwie DeepXDE, są potężnym

narzedziem w omijaniu bardzo wolnych, wielordzeniowych obliczeń PDE na rzecz błyskawicznej emulacji ciągłych gradientów temperatury, mapując zjawiska takie jak transfer ciepła z dziennej na nocną stronę zablokowanych egzoplanet.[18]

4.2 Maszyny Ekstremalnego Uczenia (Extreme Learning Machines - ELMs)

Podczas gdy modele klimatyczne ogólnej cyrkulacji (GCM), takie jak model ROCKE-3D stworzony przez NASA GISS, rozwiązują fizyczne równania procesów w obrębie drobiazgowych siatek trójwymiarowych, trwają one po prostu zbyt długo dla środowiska eksploracyjnego.[1] Aby generować miliony symulacji zespołowych (ensemble studies), badacze stosują architektury zastępcze (surrogate models) bazujące na maszynach ELM.[1]

Architektura Extreme Learning Machines to bezgradientowa alternatywa dla klasycznych głębokich sieci perceptronowych.[1] W klasycznym podejściu gradientu spadkowego, optymalizacja warstw ukrytych pochłania epoki obliczeń.[1] ELM natomiast korzysta z pojedynczej warstwy ukrytej węzłów, gdzie wagi i obciążenia warstwy wejściowej są generowane stochastycznie i pozostają zamrożone (fixed).[1] Wagi wyjściowe określane są jednoetapowo, analitycznie poprzez wykorzystanie pseudoodwrotności Moore'a-Penrose'a w macierzach.[1]

Matematyczna elegancja takiego podejścia prowadzi do skrajnego przyspieszenia czasu uczenia (training time) — często do 100 000 razy szybciej niż w przypadku klasycznych dwukierunkowych powtarzalnych sieci (Bi-RNN) przy przetwarzaniu transferu radiacyjnego.[1] W przypadku wektorów o ogromnej przestrzeni wielowymiarowej (jak modele topografii i ciśnień całych planet), zjawisko degradacji przestrzennej rozwiązuje się grupując dziesiątki algorytmów ELM w jeden zespół klasyfikujący (ELM Ensemble).[1] Pozwala to niemal natychmiast trenować emulatory bez żmudnego strojenia hiperparametrów, co uwalnia potężne zasoby programistów (korzystających ze środowisk scikit-elm czy TfELM opartych o standardy scikit-learn).[25]

4.3 Generatywne Sieci Przeciwstawne (CGAN) i Problem Klasy Mniejszościowej

Jednym z najpoważniejszych wyzwań w analizie setek tysięcy obiektów w archiwach astronomicznych (jak baza Kepler czy TESS) jest ekstremalny problem braku równowagi klasowej (severe class imbalance).[1] Spośród tysięcy planet potwierdzonych tranzytem, przeważająca większość to wrogie życiu gazowe olbrzymy, sterylnie zamarznięte światy błądzące, bądź roztopione kawałki skał.[1] Światy w optymistycznej zonie zamieszkiwalnej stanowią mniej niż ułamek procenta bazy danych.[28] Algorytmy analityczne takie jak regresja logistyczna ignorują te odchylenia, uzyskując paradoksalnie 99-procentową celność po prostu ucząc się fałszywego odrzucania wszystkich planet jako martwych, z czułością wynoszącą

absolutne zero dla planety podobnej do Ziemi.[1]

Rozwiązaniem tego kryzysu jest implementacja Warunkowych Generatywnych Sieci Przeciwstawnych (Conditional Generative Adversarial Networks - CGANs).[1] Struktura GAN składa się z architektur rywalizujących ze sobą: generatora (syntetyzującego wysoce sztuczne kombinacje danych egzoplanet z parametrami umożliwiającymi zamieszkanie) oraz dyskryminatora (próbującego wykryć oszustwo poprzez porównanie danych generatora z autentycznymi znaleziskami z teleskopu TESS).[1]

Warunkując te sieci na matematycznych wskaźnikach (ESI, HITE), generator uczy się potężnej wielowymiarowej dystrybucji zdatności do zamieszkania.[1] Po zakończeniu epok uczenia, CGAN wypełnia przestrzeń wektorów realistycznymi syntetycznymi planetami (wzbogacenie mniejszościowe), pozwalając następnie na przetrenowanie agresywnych drzew decyzyjnych (np. biblioteka XGBoost) zdolnych o wiele precyzyjniej wyodrębniać niuanse sygnałów na obrzeżach kosmicznych możliwości z celnością na testach ślepych sięgającą ponad 96 procent.[1]

5. Ekosystemy Danych Planetarnych i Integracja API

Podstawą dla każdego cyfrowego bliźniaka jest wolumin, czystość i proces inżynieryjny pobranych zasobów informacyjnych.[1] Astrobiologiczne emulacje opierają się na połączeniu potężnych obserwacyjnych API ze znormalizowanymi danymi symulacyjnymi wielkich instytutów. Zrozumienie narzędzi łączących aplikacje z tymi światami pozwala transformować dane w ramy projektowe.

5.1 Archiwum Egzoplanet NASA (NASA Exoplanet Archive)

Archiwum to jest wiodącym i krytycznym zbiorem zatwierdzonych systemów z misji tranzytowych, radialnych oraz mikrosoczewkowania grawitacyjnego.[1] Nowoczesny system integracji do aplikacji odbywa się poprzez protokoły Table Access Protocol (TAP) obsługiwane standardami zapytań SQL lub poprzez bezpośrednie Endpointy API.[1] Oprogramowanie może pobierać strumienie danych przy użyciu języka Python, agregując takie kluczowe kolumny jak masy gwiazdowe (st_mass), promienie planet (pl_rade), strumienie naświetlania (pl_insol) i orbity mimośrodowe.[33] Odpowiednia preparacja tych zestawów za pomocą biblioteki pandas (imputacja braków danych, czyszczenie szumów w seriach czasowych) dostarcza materiał podstawowy dla algorytmów.[34]

5.2 Struktury ROCKE-3D GCM i Bazy Danych NetCDF

O ile zbiory obserwacyjne zapewniają wykrycie orbity, o tyle zbiory wyjściowe z dużych globalnych modeli cyrkulacji są sercem emulacji bliźniaczych. System ROCKE-3D (Resolving Orbital and Climate Keys of Earth and Extraterrestrial Environments with Dynamics) jest silnikiem napędowym klimatologii w instytucie GISS.[1] Zamiast tworzyć logikę cyrkulacji od

absolutnego zera na hackathonie, architekci bazują na publicznych repozytoriach wyników GCM wygenerowanych po latach działania superkomputerów NASA.[1]

Dane z archiwów zapisywane są w wielowymiarowym układzie plików NetCDF (Network Common Data Form) o rozdzielczości standardowo wynoszącej 4 na 5 stopni.[1] Za pomocą bibliotek do ekstrakcji siatek trójwymiarowych, modele AI uczą się na takich zjawiskach wyciągniętych ze zrzutów danych jak: ułamek lodu morskiego (Sea Ice Fraction), wysokość 500 hPa dla atmosfery, zlokalizowany wskaźnik albedo powłoki chmur, wiatr strefowy, rozkład cieplny czy tempo utraty wody.[1]

Tabela 2 obrazuje wybrane kategorie zmiennych kluczowe dla cyfrowego mapowania w architekturach emulacyjnych:

Kategoria Zmiennej	**Wyodrębnione Cechy Ciągłe z Siatek GCM**	**Narzędzie Emulacyjne dla Cyfrowego Bliźniaka**
Termodynamiczna	Temperatura Powierzchni, Wchłonięte Światło	Przewidywanie wąskiego paska habitowalnego (strefy terminatora) dla świata zamkniętego pływowo. [1]
Hydrologiczna	Poziom Opadowy, Wilgotność Gleby	Rejestrowanie mechanizmów transportu i ewaluacja możliwości uformowania prądów w kształcie "homara". [1]
Kriosferyczna	Lód Morski (%), Głębokość Czaszy Śnieżnej	Symulowanie katastrofy zlodowacenia i siły sprzężenia zwrotnego rozszerzalności lodu (ice-albedo). [1]

5.3 Generator Widm Planetarnych (PSG - Planetary Spectrum Generator)

Planetary Spectrum Generator jest pakietem modeli do bezwzględnego transportu radiacyjnego (radiative transfer), symulującym zjawiska optyczne.[38] Udostępnia on interfejs Application Program Interface (API) z którym można komunikować się używając standardowych skryptów (np. pakiet pypsg w Pythonie) w celu wygenerowania wysokorozdzielczego sygnału widmowego - swoistego odcisku palca planety.[39] Po wysłaniu

zapytania protokołem HTTP POST (posługującym się zmodyfikowanym formatem XML wewnątrz psg_cfg.txt z parametrami planety takimi jak ciśnienie, temperatura, obfitość gazów H_2O czy CH_4, precyzyjnie sformatowanymi dla modułów PSG), serwer NASA wykonuje integrację rozpraszania wielokrotnego (multiple scattering) i odsyła tekstowe tabele ASCII. Wyniki bezpośrednio emulują to, co by zobaczono przez teleskop Jamesa Webba z uwzględnieniem kalibracji matryc i poziomów zaszumienia instrumentów spektroskopowych.[38]

5.4 Biblioteki Lightkurve dla Analiz Erozji i Światła

Praca z surowymi krzywymi zmian blasku gwiazd, kluczowa przy wykrywaniu uderzeń potężnych rozbłysków rentgenowskich (flares) na egzoplanety, napędzana jest przez bibliotekę lightkurve wykorzystującą dane z platformy MAST.[41] Oprogramowanie to łączy strumienie detekcji światła, wykonuje analizę okresową Lomb-Scargle do wykrywania orbit oraz korzysta z korektorów takich jak PLDCorrector (Pixel Level Decorrelation), aby oddzielić szumy oprzyrządowania statku kosmicznego od obiektywnych sygnałów gwiazdowych.[42] W połączeniu z pylonami detekcji rozbłysków typu AltaiPony, cyfrowy bliźniak jest w stanie skategoryzować jak intensywnie strefa gwiazdowa "bombarduje" egzosferę swoimi emisjami.[45]

6. Zintegrowane Architektury Projektowe dla HACK-4-SAGES (Kategoria 3)

Posiadając fundament w postaci głębokiej wiedzy fizycznej, precyzyjnych narzędzi AI i bogatych katalogów danych, opracowano poniżej zoptymalizowane propozycje konkretnych projektów (blueprints) na potrzeby hackathonu HACK-4-SAGES w domenie "Cyfrowe Bliźniaki w Zdatności Egzoplanet do Zamieszkania".[1] Są one wysoce innowacyjne, celują w natychmiastowy "Efekt WOW" i są ułożone pod kątem fizycznej możliwości wdrożenia prototypu w trakcie 72-godzinnego sprintu z wykorzystaniem nowoczesnych ram takich jak Streamlit.

Poniższe sekcje integrują zapytania projektowe transformując je w kompleksowe pipeline'y programistyczne.[1]

Koncepcja 1: Probabilistic Habitability Classification Pipeline (Silnik Klasyfikacji)

Tło Problemu: Historycznie oceniano planetę na zasadzie "wchodzi w strefę Złotowłosej (Goldilocks) lub nie".[1] Samodzielne krążenie we właściwej odległości absolutnie nie gwarantuje powstania życia. Ponadto, algorytmy padają ofiarą zjawiska dysbalansu bazy danych — uczą się ślepego ignorowania potencjalnych bliźniaków Ziemi.[1]

Logika Cyfrowego Bliźniaka: Zmiana paradygmatu polegająca na transformacji zjawiska binarnych stref przestrzennych we wskaźnik probabilistyczny (prawdopodobieństwa

statystycznego), gdzie ocena habitability planety stanowi wynik funkcji ciągłej, generującej matematyczną korelację w oparciu o modele fizyczne.

Architektura Implementacji:

Projekt wymaga skonstruowania trzystopniowego algorytmu:

1. **Rozszerzenie Danych (Oversampling z AI):** Pobranie danych o potwierdzonych systemach z bazy NASA poprzez TAP (Table Access Protocol) w bibliotece Python pandas.[33] Sieć Warunkowa CGAN na podstawie wąskiej bazy "planet ziemskich" zostaje wytrenowana do masowej syntezy tysięcy realistycznych egzoplanet w pełni gotowych do zamieszkania.[1] Powoduje to wymuszone, lecz fizycznie autentyczne zbilansowanie zbioru treningowego.[1]
2. **Inżynieria Cech i Kalkulacja Metryk:** Kod algorytmicznie przelicza dla każdego ciała wieloparametrowe dystanse matematyczne oparte o siły uwarunkowań — w tym Indeks ESI, równanie dla szans zablokowania pływowego (Tidal Locking Probability) oraz parametry HITE.[1]
3. **Filtr XGBoost (Klasyfikator Skoncentrowany):** Ekosystem XGBoost uczy się rozpoznawania nieliniowych sprzężeń sygnałowych z wygenerowanych cech. Nie outputuje on prostego etykietowania, ale zkalibrowaną siłę prawdopodobieństwa (od 0.000 do 1.000).[1]

Efekt WOW i UI: Budowa interaktywnego webowego dashboardu w Streamlit zachowującego się jak predykcyjny silnik kategoryzacji.[1] Badacz wprowadza do interfejsu (suwaki lub wpisanie odkrycia z TESS/JWST) dane o masie gwiazdy, masie planety, orbicie i głębokości tranzytu. Algorytm w ułamku sekundy klasyfikuje planetę jako martwą lub podaje dokładne prawdopodobieństwo utrzymania płynnej wód i biosfery (np. 89.4%). Aby podnieść imponujący charakter prezentacji sędziowskiej, użyte mogą zostać wartości SHAP (SHapley Additive exPlanations), ukazując krystalicznie czystą, kolorową wykresową interpretację dla widowni — dokładnie ilustrującą *dlaczego* algorytm uznał to środowisko za bezpieczne lub bezużyteczne.[30] Zastępuje to miesiące żmudnych poszukiwań fizyków jedną aplikacją przesiewową.

Koncepcja 2: Błyskawiczny Cyfrowy Bliźniak Klimatu (Exo-Climate Fast-Track)

Tło Problemu: Obliczanie topografii temperaturowej na siatkach atmosferycznych obcej planety zajmuje potężnym superkomputerom używającym modeli matematyki Navier-Stokesa wiele dni dla pojedynczej kombinacji pierwiastków.[1]

Logika Cyfrowego Bliźniaka: Koncepcja polega na zbudowaniu emulatora GCM (General Circulation Model Surrogate), w którym model ML wchłania lata wiedzy ukrytej w siatkach równań różniczkowych NASA, po czym zjawiskowo potrafi naśladować modelowanie 3D z opóźnieniem zaledwie rzędu sekund, pozwalając na nieustanną manipulację przez użytkownika

i natychmiastowe wizualne mapowanie wyników termodynamicznych na globy.[1]

Architektura Implementacji:

1. **Ekstrakcja Siatek Termicznych:** Kod korzysta z plików NetCDF publicznych wyników z ROCKE-3D GCM (np. scenariusze typu Archean Earth, anoxic environments).[1] Wektorowane są sferyczne siatki temperatury, poziomu zachmurzenia, formacji lodu względem stężeń atmosferycznych i rotacji.
2. **Emulacja Maszynami ELM:** Zespół scikit-elm buduje warstwę sieci neuronowej operującej na ekstremalnych modelach uczenia (Ensemble of ELMs).[1] Jako potężne bezgradientowe silniki nie iterujące epok wstecznych, algorytmy te dosłownie "zgadują" ciężary warstw wejściowych, po czym precyzyjną, odwróconą macierzą geometryczną definiują siatki docelowe, eliminując przestoje.[1] Osiągnięcie zdolności predykcji zmian prądów na siatce po podaniu sygnału odbywa się z tysiąckrotnym mniejszym kosztem energetycznym.[1]

Efekt WOW i UI: Panel Streamlit, przypominający aplikację zarządzającą światem. Użytkownik wykorzystuje suwaki dla odległości orbity, stężenia wody i masy gwiazdy. Ułamek sekundy później aplikacja zwraca Plotly.graph_objects.Figure wykreślające precyzyjnie generowaną sferę topograficzną nałożoną na 3D z wykorzystaniem mapy ciepła (heatmap).[48] Zmiana dystansu suwaka wywołuje na oczach sędziów zjawisko wejścia planety w próg powłoki lodowej i całkowite "zamrożenie" oceanu w czasie wirtualnym, dowodząc brutalności sprzężenia zwrotnego *Ice-Albedo*.[1]

Koncepcja 3: Terminator Zone Biosphere Modeler (Model Strefy Zmierzchu)

Tło Problemu: Olbrzymia ilość planet we wszechświecie w potencjalnych ekosferach krąży niezwykle blisko M-karłów, popadając w synchroniczną rotację tidal-locking.[1] Oznacza to absolutne stopienie się strony oświetlonej i kosmiczne zimno po drugiej stronie. Życie na nich — by przetrwać — musi migrować w pas wąskiego pierścienia cienia (Terminator Line) - sfery absolutnego i wiecznego zmierzchu.[1]

Logika Cyfrowego Bliźniaka: Zmiana perspektywy z prostej oceny na system równań dynamicznych — zbadanie, czy efektywność fizycznych prądów wodnych i wietrznych jest tak precyzyjna, że nadmiar destrukcyjnego ciepła przenoszony jest ku lodowej pokrywie na mrok globu, pozwalając planecie uchronić się przed załamaniem zjawiska życia.[1]

Architektura Implementacji:

Ta koncepcja rezygnuje ze zwykłej bazy danych na rzecz czystych równań matematycznych dla pasjonatów programowania analitycznego.

1. **Rozwiązywanie Równania Różniczkowego (PINN):** Projekt aplikuje bibliotekę np. DeepXDE pod Python w celu stworzenia sieci PINN, implementującej sferyczne równanie

ciągłości dyfuzji ciepła z prądami wymuszonymi jako czynnik (tzw. zjawisko zrównoważenia równikowych prądów "homara" / lobster state).[1]
2. **Karalność Sieci:** Sieć jest uczona karania swoich własnych przewidywań funkcji dystrybucji, jeśli ciepło pojawi się bez przyczyny fizycznej w niewłaściwym pasie globusa.[1]

Efekt WOW i UI: W interfejsie graficznym generowana jest biblioteką graficzną piękna trójwymiarowa kula. Gradient kolorów ewoluuje w procesie ciągłym. Gdy algorytm doprowadzi termodynamikę do stabilizacji, system precyzyjnie kalkuluje pasmo o grubości kilkuset kilometrów na granicy globu (strefa między 0 stopni Celsjusza a 40 st. C) i podświetla ten idealnie wąski pierścień, obracając nim na ekranie, jaskrawym kolorem zielonym.[1] Obrazuje to natychmiastowe wizualne mapowanie frakcji mieszkalnej. To absolutny dowód zrozumienia trudnej mechaniki równań cząstkowych PDEs (Partial Differential Equations) użytych do rozwiązywania kosmicznych zagadek płynów w trybie real-time.[1]

Koncepcja 4: Red Dwarf Flare Survival Simulator (Symulator Erozji Promieniowaniem)

Tło Problemu: Astrofizyka klasyfikuje systemy planetarne takie jak u czerwonego karła TRAPPIST-1 jako najlepszych kandydatów na egzystencję życia pozaziemskiego ze względu na ich występowanie w wytyczonej linii temperaturowej (HZ).[1] Przemilcza się gigantyczny defekt tych systemów: gwiazdy te posiadają niestabilne, brutalne pola magnetyczne generujące niszczycielskie wyrzuty rentgenowskie, które zdmuchują pierwotne atmosfery niczym piasek z dłoni na wietrze.[1]

Logika Cyfrowego Bliźniaka: Zamiana podejścia "czy woda tu jest stabilna termicznie" na model inżynierii bezpieczeństwa atmosferycznego — ocenienie realnego stopnia ochrony osłon i długości istnienia tego środowiska zanim XUV zniszczy biosferę i usunie gazy cieplarniane ze stratotermostery.[1]

Architektura Implementacji:

1. **Obróbka Sygnałów Światła:** Oprogramowanie integruje strumienie TESS wykorzystując genialny protokół Python o nazwie lightkurve i AltaiPony.[41] Skrypty detrendują artefakty ruchów samej rakiety i optyki satelity (zjawiska PLDCorrector).[44]
2. **Modelowanie Uderzeniowe (Flare Bombardment):** Wyekstrahowana dystrybucja potężnych uderzeń promieniotwórczych (Flare Frequency Distribution) jest mapowana jako uderzenia w modelu erozji hydrodynamicznej egzosfery nowej, symulowanej planety.[9] Algorytm wylicza rozszerzalność gazową układu oraz odrywanie się elementów od warstw.[1]

Efekt WOW i UI: Aplikacja ma mroczny, analityczny wygląd powiązany z kosmiczną brutalnością (Space Weather Threat Analyzer).[1] Użytkownik wskazuje docelową gwiazdę o znanej egzosferze (np. TRAPPIST-1). Algorytm ukazuje dynamiczny wykres utraty ułamka

objętości wody czy atmosfery zbiegający ku ziemi. Zamiast banalnej, powtarzanej w kółko tezy "to planeta w ekosferze!", interfejs wystawia drastyczny i chłodny fizyczny wyrok: "Metryka zdatności zniszczona. Gwiazda-matka sterylizuje i wyeroduje jej biosferę w 14.3 miliona lat. Atmosferyczny Czas Retencji (Retention Time) został zrównany z zerem".[1] Ta nowatorska rygorystyczność jest dla jury niepodważalnie oryginalna.

Koncepcja 5: Generator Syntetycznych Widm dla Teleskopu Webba (Synthetic JWST Pipeline)

Tło Problemu: Przyszłość wykrywania biosygnatur biologicznych (np. oddychania lasów czy sinic na obcych oceanach) opiera się o potężny sprzęt spektroskopowy JWST.[1] Mamy jednak gigantyczny problem: AI doskonale rozpoznaje obiekty tylko, gdy ma obfite dane treningowe. A przecież nie posiadamy zbiorów danych widm z setek żywych planet-oceanów do przetrenowania przyszłych sieci — nie spotkaliśmy dotąd ani jednej z nich.[1]

Logika Cyfrowego Bliźniaka: Sieć wytwarza sztucznego bliźniaka obcej cywilizacji lub roślinności oceanicznej, emulując optykę i transport fal podczerwonych odległego źródła przechodzących przez tę niezwykłą egzosferę.[1] Pozwala wygenerować potężną kolekcję zmyślonych, acz stuprocentowo naukowo precyzyjnych i wysoce realistycznych sygnatur, na jakich astrobiolodzy w laboratoriach na całym świecie mogą następnie uczyć systemy wykrywające obce organizmy.[1]

Architektura Implementacji:

Projekt korzysta z oficjalnej technologii NASA jako backendu operacyjnego.

1. **Zrozumienie Modelu Gazowego:** Za pomocą modeli generowanych (rozszerzenie z Koncepcji 1 lub ręcznej kalibracji planety wodnej o bogatym w biosferę równaniu z gazami cieplarnianymi).
2. **API PSG NASA:** Konfiguracja XML parametru planety zostaje wysłana poprzez wywołanie HTTP POST do instytutu (lub użyto skryptowania pypsg) w protokołach Planetary Spectrum Generator.[39]
3. **Filtr Teleskopu:** Do parametru uderza symulacja zakłóceń szumowych samego detektora NIRSpec oraz MIRI w teleskopie Webba, która nadpisuje te pakiety symulując rzeczywiste detekcje gwiezdne z milionów lat świetlnych.[1]

Efekt WOW i UI: Panel tworzy w ułamku sekundy gotowe pliki binarne dla inżynierów badawczych pod model AI. "Dostarczamy astrofizykom zmyślone, ale idealne zasoby do testowania detektorów, rozwiązując kryzys niedostatku obcych danych w astronomii." Aplikacja demonstruje interaktywny wykres wyciętego światła na danych z PSG. W rękach studentów MiNI PW to potężne pociągnięcie, gdyż projekt staje się gotowym do skomercjalizowania we framewokach open-source inżynieryjnym narzędziem pomocniczym dla naukowców o statusie użyteczności instytutowej.[1]

7. Analiza Wykonalności w Realiach Hackathonu i Skala Złożoności

Realizacja projektów łączących zaawansowaną astrofizykę i głębokie modele neuronowe w ramach 72–96 godzin trwania zmagania z programowaniem stanowi wyzwanie, jednakże wyselekcjonowane w raporcie struktury opierają się na technologiach ułatwiających zręczny deployment i optymalizację wysiłku zespołu programistycznego.

Harmonogram pracy zespołowej (Grupa 3-4 osób o kompetencjach MiNI PW):

1. **Kierunek "Inżynieria Danych (Data/API Engineer)"**: Odpowiada za uderzenia protokołami TAP w NASA Exoplanet Archive (zapytania SQL filtrujące tranzyty), implementację zapytań cURL/pypsg do platformy NASA PSG oraz ładowanie TESS FFD poprzez pliki lightkurve.[1]
2. **Kierunek "Inżynieria Algorytmów ML (ML Architect)"**: Zajmuje się czystą matematyką i kalibracją struktury, taką jak projektowanie architektury ELM, konfiguracja siatki granicznej dla warunków brzegowych w bibliotece DeepXDE (na poczet sieci PINN) lub trening hybrydy CGAN z gradientowym modelem XGBoost.[1]
3. **Kierunek "Frontend / Ekspertyza UX (Full-Stack/Data-Viz)"**: Kompletna budowa panelu w systemie szybkiego wdrażania w języku Python (Streamlit), połączona z renderowaniem siatek trójwymiarowych sfer w bibliotece Plotly (zjawiska 3D scatter na współrzędnych sferycznych powiązane ze zjawiskami na globach).[1]

Zastosowanie asysty AI (GitHub Copilot)

W oparciu o specyfikację, zespoły mogą bezwzględnie zastosować narzedzia generacji LLM do przejęcia ciężaru żmudnego pisania klas łączących i zapytań. Tworzenie boilerplate'u kodu dla integracji Streamlit z wizualizacjami matplotlib/plotly, pisanie reguł parsujących surowe tekstowe tabele bazy NetCDF lub ASCII (format zwrotny z PSG) czy deklaracja powtarzalnych elementów strukturalnych funkcji straty (Loss Function) mogą z powodzeniem zostać narzucone automatyzacji, umożliwiając deweloperom poświęcenie kluczowego czasu na precyzyjną optymalizację metryk walidacyjnych.

Ewaluacja Konkurencyjna Systemu Podczas gdy amatorskie zespoły tworzą na hackathonie banalne proste aplikacje opierające się na ręcznym przypisywaniu statystyk z Wikipedii, rygorystyczny aparat koncepcyjny zarysowany powyżej ocenia fundamentalne, matematyczne modele symulacyjne przy użyciu sprawdzonych narzędzi statystycznych.[1] Optymalizacja algorytmów pod kątem metryki "Macro F1" skutecznie niszczy iluzje standardowej oceny wiarygodności przy skrajnych, mniejszościowych zestawach planetarnych, ocalając system przed degradacją przewidywań algorytmicznych.[1] Walidacje sieci PINN poprzez monitorowanie residualnych uchybień praw dyfuzji ciepła gwarantują, że silnik termodynamiczny planety faktycznie wykonuje pracę termiczną z poszanowaniem zasad wymiany radiacyjnej gwiazdy do wirtualnej wody i masy.[1] Zbudowanie którejkolwiek z proponowanych architektur i ich odpalenie

na typowym sprzęcie w tak skrajnym czasie potwierdzi niezwykłą biegłość zespołu inżynieryjnego.

8. Wnioski Końcowe

Przekrój łączący astrofizykę, matematykę stosowaną i techniki głębokiego uczenia wyznacza absolutną granicę badawczą i obliczeniową współczesnych działań nad egzosferami i pojęciem życia w kosmosie.[1] Biorąc pod uwagę masowy zalew fotometrycznych i spektroskopowych wskaźników płynących bezustannie na serwery z orbit, przepustowość technologii z interpretacji i oceny modeli klasycznych uległa załamaniu z powodu opóźnień obliczeniowych.

Wdrożenie paradygmatu systemów typu Cyfrowe Bliźniaki stanowi nieuniknioną drogę ewolucyjną w tej gałęzi nauki.[1] Integracja złożonych zjawisk fizycznych i termodynamicznych — wymian chłodzenia, promieniowania gwiezdnego w pasmach UV czy rezonansowego zablokowania pływowego — za pomocą innowacyjnych klasyfikatorów takich jak Sieci Przeciwstawne (CGAN), wskaźników statystycznych (SEPHI), potężnych Emulatorów Ekstremalnych (ELM) oraz inspirowanych zjawiskami termicznymi modeli dyfuzji (PINN), rozwiązuje paradygmatyczne bolączki środowiska naukowego.[1]

Dla interdyscyplinarnych inicjatyw technologicznych z obszaru Astrobiologii — w szczególności wdrożeń ukierunkowanych na zawody HACK-4-SAGES, gdzie decyduje zarówno rygor naukowy, spójność kodu, jak i uderzeniowy efekt wizualny — zastosowanie przedstawionych koncepcji zapewnia opracowanie narzędzi potężnych i nieocenionych w symulacyjnej wizualizacji kosmosu.[1] Prezentowane projekty gwarantują innowacyjne wsparcie dla ról, z jakimi dzisiaj potężne instytucje badawcze zmagają się przy detekcji pozaziemskich, ukrytych w nieskończoności form sygnatur biologicznych na odległych ciałach skalistych.[1]

Cytowane prace

1. AI_ML Exoplanet Digital Twin Ideas (1).pdf
2. Accelerating Exoplanet Climate Modelling: A Machine Learning Approach To Complement 3D GCM Grid Simulations - Astrobiology, otwierano: lutego 22, 2026, https://astrobiology.com/2025/08/accelerating-exoplanet-climate-modelling-a-machine-learning-approach-to-complement-3d-gcm-grid-simulations.html
3. FAQ - HACK-4-SAGES, otwierano: lutego 22, 2026, https://hack-4-sages.org/faq/
4. HACK 4 SAGES: Digital Twins in Astrobiology – call for students and mentors - DEADLINE 23.02.2026 - ENHANCE, otwierano: lutego 22, 2026, https://enhance.pw.edu.pl/enhance_en/ENHANCE/News/HACK-4-SAGES-Digital-Twins-in-Astrobiology-call-for-students-and-mentors-DEADLINE-23.02.2026
5. [1509.08922] Comparative Habitability of Transiting Exoplanets - arXiv, otwierano: lutego 22, 2026, https://arxiv.org/abs/1509.08922
6. Exoplanets: Habitability and Characterization (Chapter 15) - Atmospheric Evolution on Inhabited and Lifeless Worlds - Cambridge University Press &

Assessment, otwierano: lutego 22, 2026, https://www.cambridge.org/core/books/atmospheric-evolution-on-inhabited-and-lifeless-worlds/exoplanets-habitability-and-characterization/33D8F1E76906A2086B3CB45FA516DF04
7. imcs-compsim/pinns_for_comp_mech: Implementation of Physics-Informed Neural Networks for Computational Mechanics based on the DeepXDE package. - GitHub, otwierano: lutego 22, 2026, https://github.com/imcs-compsim/pinns_for_comp_mech
8. Simulating the impact of stellar flares on the climate and habitability of terrestrial Earth–like exoplanets - University of Exeter - Figshare, otwierano: lutego 22, 2026, https://ore.exeter.ac.uk/articles/thesis/Simulating_the_impact_of_stellar_flares_on_the_climate_and_habitability_of_terrestrial_Earth_like_exoplanets/29795954
9. Effect of stellar flares on atmospheric escape of terrestrial planets (Laura Amaral, ASU), otwierano: lutego 22, 2026, https://www.youtube.com/watch?v=dHz-95fF8fc
10. The Effect of a Strong Stellar Flare on the Atmospheric Chemistry of an Earth-like Planet Orbiting an M Dwarf - PMC, otwierano: lutego 22, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC3103837/
11. Stellar Flares in the TESS Light Curves of Planet-hosting M dwarfs - arXiv, otwierano: lutego 22, 2026, https://arxiv.org/html/2511.13716v1
12. Earth Similarity Index (ESI) - PHL @ UPR Arecibo, otwierano: lutego 22, 2026, https://phl.upr.edu/projects/earth-similarity-index-esi
13. Statistical-likelihood Exo-Planetary Habitability Index (SEPHI) | Monthly Notices of the Royal Astronomical Society | Oxford Academic, otwierano: lutego 22, 2026, https://academic.oup.com/mnras/article/471/4/4628/4096396
14. Statistical-likelihood Exo-Planetary Habitability Index (SEPHI) - Oxford Academic, otwierano: lutego 22, 2026, https://academic.oup.com/mnras/article-pdf/471/4/4628/19635263/stx1910.pdf
15. [PDF] Statistical-likelihood Exo-Planetary Habitability Index (SEPHI) - Semantic Scholar, otwierano: lutego 22, 2026, https://www.semanticscholar.org/paper/Statistical-likelihood-Exo-Planetary-Habitability-Mozos-Moya/e311b23ab5a55a85ad9c9af3d633f661f75bdb69
16. Potentially Habitable Terrestrial Exoplanets based on the Habitability Index for Transiting Exoplanets (HITE) Value - ejournal brin, otwierano: lutego 22, 2026, https://ejournal.brin.go.id/ijoa/article/download/5505/10627/39303
17. HACK-4-SAGES – Digital Twins in Astrobiology Hackathon, otwierano: lutego 22, 2026, https://hack-4-sages.org/
18. DeepXDE: A Deep Learning Library for Solving Differential Equations | SIAM Review, otwierano: lutego 22, 2026, https://epubs.siam.org/doi/10.1137/19M1274067
19. Heat equation — DeepXDE 1.15.0 documentation, otwierano: lutego 22, 2026, https://deepxde.readthedocs.io/en/stable/demos/pinn_forward/heat.html
20. ROCKE-3D 2.0: an updated general circulation model for simulating the climates of rocky planets - GMD, otwierano: lutego 22, 2026, https://gmd.copernicus.org/articles/18/5825/2025/

21. SciML/Surrogates.jl: Surrogate modeling and optimization for scientific machine learning (SciML) - GitHub, otwierano: lutego 22, 2026, https://github.com/SciML/Surrogates.jl
22. Build an Extreme Learning Machine in Python | by Glenn Paul Gara | TDS Archive | Medium, otwierano: lutego 22, 2026, https://medium.com/data-science/build-an-extreme-learning-machine-in-python-91d1e8958599
23. Extreme Learning Machine Neural Network - Kaggle, otwierano: lutego 22, 2026, https://www.kaggle.com/code/andreicosma/extreme-learning-machine-neural-network
24. [2506.19679] Extreme Learning Machines for Exoplanet Simulations: A Faster, Lightweight Alternative to Deep Learning - arXiv, otwierano: lutego 22, 2026, https://arxiv.org/abs/2506.19679
25. TfELM: Extreme Learning Machines framework with Python and TensorFlow, otwierano: lutego 22, 2026, https://research-repository.uwa.edu.au/en/publications/tfelm-extreme-learning-machines-framework-with-python-and-tensorf/
26. akusok/scikit-elm: Extreme Learning Machine (ELM) with Scikit-Learn compatibility - GitHub, otwierano: lutego 22, 2026, https://github.com/akusok/scikit-elm
27. pyExtremeLM is a python module, which implements the extreme learning machine, in the style of scikit-learn. - GitHub, otwierano: lutego 22, 2026, https://github.com/tobifinn/pyextremelm
28. Habitable exoplanet - a statistical search for life - Frontiers, otwierano: lutego 22, 2026, https://www.frontiersin.org/journals/astronomy-and-space-sciences/articles/10.3389/fspas.2025.1674754/full
29. Analysis of Habitability and Stellar Habitable Zones from Observed Exoplanets - MDPI, otwierano: lutego 22, 2026, https://www.mdpi.com/2075-4434/12/6/86
30. Predicting Exoplanet Habitability Using Machine Learning - NORMA@NCI Library, otwierano: lutego 22, 2026, https://norma.ncirl.ie/8541/1/debayanbiswas.pdf
31. NASA Exoplanet Archive Overview and Holdings - Caltech, otwierano: lutego 22, 2026, https://exoplanetarchive.ipac.caltech.edu/docs/intro.html
32. Retrieving Exoplanet Archive Data With Table Access Protocol, otwierano: lutego 22, 2026, https://exoplanetarchive.ipac.caltech.edu/docs/TAP/usingTAP.html
33. Using the Application Programming Interface (API) - NASA Exoplanet Archive - Caltech, otwierano: lutego 22, 2026, https://exoplanetarchive.ipac.caltech.edu/docs/program_interfaces.html
34. How to Explore NASA Exoplanet Archive Data with Python and Pandas - DEV Community, otwierano: lutego 22, 2026, https://dev.to/stevenbruno/how-to-explore-nasa-exoplanet-archive-data-with-python-and-pandas-351g
35. Classification of dataset of exoplanets(phl_hec_all_confirmed) based on habitability - GitHub, otwierano: lutego 22, 2026, https://github.com/adivar99/Exoplanet-Habitability

36. Simulations of Planetary Climates with ROCKE-3D - Data.GISS, otwierano: lutego 22, 2026, https://data.giss.nasa.gov/rocke3d/maps/
37. Is Earth the exception? - Diva Portal, otwierano: lutego 22, 2026, https://uu.diva-portal.org/smash/get/diva2:2023931/FULLTEXT01.pdf
38. Fundamentals of the Planetary Spectrum Generator, otwierano: lutego 22, 2026, https://psg.gsfc.nasa.gov/images/help/handbook.pdf
39. Planetary Spectrum Generator - NASA, otwierano: lutego 22, 2026, https://psg.gsfc.nasa.gov/helpapi.php
40. gbaydin/pypsg - GitHub, otwierano: lutego 22, 2026, https://github.com/gbaydin/pypsg
41. lightkurve/lightkurve: A friendly package for Kepler & TESS time series analysis in Python. - GitHub, otwierano: lutego 22, 2026, https://github.com/lightkurve/lightkurve
42. Tutorials — Lightkurve - GitHub Pages, otwierano: lutego 22, 2026, https://lightkurve.github.io/lightkurve/tutorials/
43. Measuring and Removing a Rotation Period Signal from a Kepler Light Curve — MAST Notebook Repository - GitHub Pages, otwierano: lutego 22, 2026, https://spacetelescope.github.io/mast_notebooks/notebooks/Kepler/measuring_a_rotation_period/measuring_a_rotation_period.html
44. Removing noise from K2 and TESS light curves using Pixel Level Decorrelation (PLDCorrector) — Lightkurve - GitHub Pages, otwierano: lutego 22, 2026, https://lightkurve.github.io/lightkurve/tutorials/2-creating-light-curves/2-3-k2-pldcorrector.html
45. Flare science in Kepler, K2 and TESS light curves — AltaiPony 2.0.0 documentation, otwierano: lutego 22, 2026, https://altaipony.readthedocs.io/
46. ekaterinailin/TESS_UCD_flares: Find and analyse flares in TESS UCD light curves - GitHub, otwierano: lutego 22, 2026, https://github.com/ekaterinailin/TESS_UCD_flares
47. Martian-maker/exo-habitability-ranker - GitHub, otwierano: lutego 22, 2026, https://github.com/Martian-maker/exo-habitability-ranker
48. st.plotly_chart - Streamlit Docs, otwierano: lutego 22, 2026, https://docs.streamlit.io/develop/api-reference/charts/st.plotly_chart
49. The Heat Equation in Higher Dimensions - Partial Differential Equations | Lecture 4, otwierano: lutego 22, 2026, https://www.youtube.com/watch?v=hvlH-knQ5ql
50. Physics-informed neural network for the heat equation under imperfect contact conditions and its error analysis - AIMS Press, otwierano: lutego 22, 2026, https://www.aimspress.com/article/doi/10.3934/math.2025364?viewType=HTML