Strategiczne Architektury Transformerowe i Generatywna Sztuczna Inteligencja w Astrobiologii Obliczeniowej: Wyczerpująca Analiza Wykonalności dla Projektów HACK-4-SAGES

Wprowadzenie do Zmiany Paradygmatu Obliczeniowego w Naukach Planetarnych

Przejście od czysto obserwacyjnej astronomii do predykcyjnej egzoklimatologii oraz poszukiwania sygnatur biologicznych stanowi jedną z najgłębszych zmian koncepcyjnych we współczesnej astrofizyce. Historycznie poszukiwania egzoplanet były zdominowane przez statystyczną akumulację odkryć, mającą na celu odpowiedź na pytanie, czy ciała planetarne poza Układem Słonecznym istnieją w znaczących liczbach.[1] Wraz z misjami takimi jak Kepler, Transiting Exoplanet Survey Satellite (TESS) oraz Kosmicznym Teleskopem Jamesa Webba (JWST), działającymi z niespotykaną dotąd rozdzielczością, dyscyplina ta ewoluowała w kierunku szczegółowej charakteryzacji atmosfer i powierzchni tych odległych światów.[1] W konsekwencji współczesna astrobiologia staje przed potężnym wyzwaniem analitycznym: zidentyfikowaniem, które z tysięcy potwierdzonych egzoplanet posiadają odpowiednie warunki fizyczne, atmosferyczne i klimatyczne do podtrzymania życia.[1] Aby sprostać ogromnej objętości i wielowymiarowości tych danych, środowisko naukowe coraz częściej opiera się na koncepcji cyfrowego bliźniaka (digital twin), będącego wysoce wyrafinowaną, stale aktualizowaną wirtualną repliką układu fizycznego.[1]

Dla oceny zdatności egzoplanet do zamieszkania, konstruowanie takich cyfrowych bliźniaków wymaga syntezy mechaniki orbitalnej, modeli irradiancji gwiazdowej oraz dynamiki płynów, co tradycyjnie realizowane jest poprzez obliczeniowo kosztowne Modele Ogólnej Cyrkulacji (General Circulation Models - GCM), takie jak system ROCKE-3D rozwijany przez NASA.[1] Jednakże przepuszczenie pojedynczej konfiguracji planetarnej przez klasyczny trójwymiarowy model GCM może wymagać tysięcy godzin obliczeniowych na superkomputerach, co czyni niemożliwym przeprowadzanie zakrojonych na szeroką skalę analiz statystycznych w środowiskach szybkiego prototypowania, takich jak 72-godzinne hackathony naukowe.[1] W związku z tym hackathon HACK-4-SAGES, koncentrujący się na zagadnieniach początków życia, detekcji biosygnatur oraz zdatności do zamieszkania, wymusza zastosowanie

innowacyjnych metod akceleracji obliczeniowej.[1]

Wcześniejsze rekomendacje technologiczne opierały się na integracji klasycznych architektur uczenia maszynowego (ML), takich jak sieci neuronowe inspirowane fizyką (Physics-Informed Neural Networks - PINN), maszyny ekstremalnego uczenia (Extreme Learning Machines - ELM) oraz warunkowe generatywne sieci przeciwstawne (Conditional Generative Adversarial Networks - CGAN).[1] Chociaż technologie te oferują znaczące przyspieszenie w stosunku do tradycyjnych solverów numerycznych, gwałtowny rozwój wielkich modeli językowych (Large Language Models - LLM), autonomicznych agentów naukowych oraz architektur opartych na mechanizmie uwagi (Transformers) wymusza rygorystyczną ewaluację ich przydatności.[2] Niniejszy raport stanowi dogłębną analizę możliwości wykorzystania technologii Transformer i modeli generatywnych (GenAI) w ramach projektów astrobiologicznych, odpowiadając na kluczowe pytanie o zasadność migracji w stronę tych nowatorskich architektur w warunkach ograniczeń czasowych, w zestawieniu z bezpieczeństwem pozostania przy technologiach uprzednio proponowanych.

Teoretyczne Podstawy Astrofizyki a Wymogi dla Cyfrowych Bliźniaków

Aby skutecznie trenować modele uczenia maszynowego dla egzoplanetarnych cyfrowych bliźniaków, niezależnie od tego, czy są to proste sieci perceptronowe, czy zaawansowane Transformery, należy najpierw ustalić podstawowe mechaniki fizyczne dyktujące klimaty planetarne. Model uczenia maszynowego jest tylko tak solidny, jak matematyczna fizyka, którą próbuje emulować; zatem głębokie zrozumienie tych planetarnych równań jest warunkiem wstępnym dla inżynierii cech i formułowania funkcji straty.[1]

Fundamentalną metryką zdatności do zamieszkania jest teoretyczna zdolność planety do utrzymania ciekłej wody na swojej powierzchni, co definiuje granice ekosfery (Habitable Zone - HZ). Głównym wskaźnikiem warunków panujących na powierzchni planety jest jej temperatura równowagowa, przy założeniu równomiernej redystrybucji ciepła, wywodząca się z prawa Stefana-Boltzmanna: $T_{eq} = (\frac{S(1-A)}{4\sigma})^{1/4}$, gdzie S reprezentuje padający strumień promieniowania gwiazdowego, A reprezentuje planetarne albedo Bonda, a σ to stała Stefana-Boltzmanna.[1] Chociaż to równanie dostarcza wyidealizowanej linii bazowej, sztuczna inteligencja musi brać pod uwagę nieliniowe efekty cieplarniane oraz dynamikę cyrkulacyjną.[1]

Kluczową kwestią dla współczesnej egzoklimatologii, szczególnie w kontekście powszechnych czerwonych karłów (gwiazd typu M), jest zjawisko zablokowania pływowego (tidal locking).[1] Planety krążące w bliskich ekosferach poddawane są intensywnym gradientom grawitacyjnym, co przez miliony lat zmusza okres rotacji do synchronizacji z okresem orbitalnym.[1] Stan rotacji jest opisywany złożonymi równaniami różniczkowymi uwzględniającymi długość podgwiezdną

γ, anomalię średnią oraz stałą dyssypację pływową opóźnienia czasowego ϵ, gdzie $\dot{\gamma} + \frac{1}{2}\omega_s^2 \sin(2\gamma) + \dot{n} + \epsilon\dot{\gamma} = 0$.[1] Skalę czasową wymaganą do osiągnięcia tego stanu szacuje się przy użyciu uproszczonego fizycznego przybliżenia zależnego od masy gwiazdy i dystansu orbitalnego.[1] Zrozumienie tej dynamiki jest absolutnie krytyczne, ponieważ wolno rotująca planeta doświadcza sił Coriolisa, które fundamentalnie zmieniają globalną cyrkulację atmosferyczną, podczas gdy planeta zablokowana pływowo opiera się całkowicie na dywergencji substelarnej (różnicy między nagrzaną stroną dzienną a zamrożoną stroną nocną) w celu transportu ciepła.[1]

Wprowadzenie globalnych oceanów do modelu planetarnego sprawia, że termodynamiczny transport ciepła (Ocean Heat Transport - OHT) staje się wysoce zlokalizowany i nieliniowy. Wysokorozdzielcze badania oparte na siatkach 3D GCM wykazały, że zablokowane pływowo akwaplanety wykazują odrębne stany klimatyczne. Słaby transport ciepła prowadzi do stanu gałki ocznej (eyeball state), z okrągłym oceanem na punkcie podgwiezdnym otoczonym lądolodem, podczas gdy wysoce wydajne prądy równikowe topią lód, skutkując stanem homara (lobster state).[1] Symulowanie tych przejść fazowych oraz brutalnych pętli sprzężeń zwrotnych, takich jak sprzężenie lód-albedo prowadzące do globalnego zlodowacenia, wymaga rozwiązywania nieliniowych równań Naviera-Stokesa na sferycznej siatce topograficznej.[1] Każda architektura sztucznej inteligencji aspirująca do miana cyfrowego bliźniaka musi udowodnić swoją zdolność do mapowania tych nieliniowości przestrzenno-czasowych.

Ograniczenia Tradycyjnych Architektur Uczenia Maszynowego w Emulacji Praw Fizyki

Aby w pełni ocenić potencjał modeli z rodziny Transformer i LLM, konieczna jest rygorystyczna dekonstrukcja ograniczeń technologii proponowanych jako klasyczny punkt odniesienia, mianowicie wielowarstwowych perceptronów wbudowanych w fizykę (MLP-PINN) oraz maszyn ekstremalnego uczenia (ELM).[1]

Podejście oparte na architekturze Physics-Informed Neural Networks rozwiązuje problem modeli czysto opartych na danych, które są fundamentalnie obojętne na prawa fizyki i często generują wyniki sprzeczne z zasadami termodynamiki.[1] Standardowe PINNy, wykorzystując np. bibliotekę DeepXDE, osadzają równania różniczkowe cząstkowe bezpośrednio w funkcji straty sieci neuronowej, karząc algorytm za naruszenie praw zachowania pędu czy energii.[1] Funkcja straty przyjmuje postać agregacji błędów względem danych obserwacyjnych, wartości resztkowej równań PDE oraz warunków brzegowych i początkowych.[1] Niemniej jednak klasyczne sieci PINN, polegające na standardowych wielowarstwowych perceptronach (MLP), napotykają na potężne przeszkody w optymalizacji. Badania nad konwergencją PINN wykazują, że architektura MLP cierpi na tzw. błąd spektralny (spectral bias). Oznacza to, że sieć szybko zbiega do rozwiązań o niskich częstotliwościach przestrzennych, całkowicie zawodząc przy

aproksymacji równań sztywnych (stiff PDEs), które charakteryzują się wysokimi częstotliwościami lub zachowaniami chaotycznymi o wielu skalach.[7] W kontekście modelowania zablokowanych pływowo egzoplanet, strefa terminatora stanowi wąski pas drastycznych zmian temperatury. Klasyczny PINN, ze względu na swoją architekturę, ma tendencję do niefizycznego rozmywania tego gradientu, co wymusza stosowanie tysięcy godzin dostrajania hiperparametrów i złożonych schematów wag dynamicznych, niwecząc korzyści czasowe w realiach hackathonu.[5]

Alternatywa w postaci maszyn ekstremalnego uczenia (ELM) oferuje architekturę bezgradientową. Zamiast iteracyjnej optymalizacji wag przez wsteczną propagację błędu, ELM wykorzystuje pojedynczą warstwę ukrytą, w której wagi wejściowe są stochastycznie zamrożone, a wagi wyjściowe wyliczane analitycznie w jednym kroku algebraicznych operacji macierzowych z wykorzystaniem pseudoodwrotności Moore'a-Penrose'a.[1] Matematyczna elegancja tego podejścia prowadzi do niewyobrażalnego wręcz przyspieszenia czasu uczenia, często czyniąc go 100 000 razy szybszym niż w klasycznych sieciach rekurencyjnych (RNN).[1] ELM doskonale radzi sobie z emulacją jednowymiarowego transferu radiacyjnego, lecz przy modelowaniu topografii całej planety z siatkami o wysokiej rozdzielczości zjawisko degradacji przestrzennej sprawia, że pojedynczy węzeł ELM traci zdolność przewidywania. Wymaga to tworzenia masywnych zespołów algorytmów (Ensemble of ELMs), które próbują agregować szczątkowe informacje o siatkach klimatycznych.[1] Choć jest to operacja niezwykle szybka pod względem wdrożenia w hackathonie, brakuje w niej natywnego zrozumienia zależności globalnych, co czyni modele podatnymi na przeoczenie korelacji między anomalią chmur na równiku a pokrywą lodową na biegunie.

Przewaga Modeli Transformerowych i Zdolności Śledzenia Uwagi (Self-Attention)

Mechanizm głębokiego uczenia ewoluował poprzez koncepcję samo-uwagi (Self-Attention), spopularyzowaną przez architekturę Transformer w przetwarzaniu języka naturalnego. W przeciwieństwie do sieci konwolucyjnych (CNN), które posiadają silne obciążenia indukcyjne (inductive bias) ograniczone do lokalnych filtrów pikselowych, oraz sieci rekurencyjnych przetwarzających dane wyłącznie sekwencyjnie krok po kroku, Transformery potrafią bezpośrednio odnosić się do dowolnego elementu w całej sekwencji danych wejściowych, niezależnie od jego odległości.[5] Obliczając skalowane iloczyny skalarne między wektorami zapytań (Queries), kluczy (Keys) i wartości (Values), model uczy się globalnej mapy zależności. Przekucie tego mechanizmu na dane fizyczne i astrobiologiczne stanowi o sile najnowszych architektur.

Physics-Informed Transformers (PINNsFormer / PhysicsFormer)

Odpowiedzią na ograniczenia błędu spektralnego klasycznych PINN jest włączenie architektury Transformer do rygoru równań różniczkowych. Inicjatywy takie jak PINNsFormer czy

PhysicsFormer przedefiniowują problem rozwiązywania PDE, transformując punktowe współrzędne przestrzenno-czasowe w pseudoskwencje, które są trawione przez bloki kodera i dekodera wielogłowicowej uwagi.[4] Co więcej, wprowadzane są nowatorskie funkcje aktywacji, takie jak funkcje falkowe (Wavelet), które antycypują dekompozycję Fouriera przez głębokie sieci neuronowe, zmuszając architekturę do wyłapywania sygnałów o wysokiej częstotliwości.[4] Zastępując punktową funkcję straty stratą sekwencyjną, adaptacyjnie przeważającą wagi fizyki, modele te potrafią modelować ostre zmiany termodynamiczne w warunkach brzegowych z błędem zredukowanym do absolutnego minimum ($O(10^{-6})$).[12] W kontekście transportu ciepła na egzoplanetach PINNsFormer zapewnia globalną propagację warunków początkowych, omijając lokalną krótkowzroczność MLP, zachowując fizyczną konsystencję termodynamiki przy jednoczesnym przyspieszeniu konwergencji na sprzęcie GPU od 2 do 3 razy.[4]

Modele Wizyjne: Spatiotemporal Vision Transformers (ST-ViT) w Emulacji GCM

Gdy problem przechodzi z czystych równań matematycznych na emulację zrzutów z modeli ROCKE-3D NetCDF o wysokiej rozdzielczości, Vision Transformers (ViT) deklasują konwolucyjne emulatory.[1] Tradycyjne sztuczne sieci nie potrafią w pełni zintegrować globalnych i nielokalnych zależności atmosferycznych z powodu wąskich pól recepcyjnych CNN.[15] Zamiast tego modele oparte na ViT tną globalne mapy planetarne, zmienne meteorologiczne i wysokości geopotencjalne na mniejsze segmenty (patches), przetwarzając je równolegle i z zachowaniem potężnego kontekstu przestrzennego.[14] Modele pokroju ST-ViT udowodniły, że redukują błędy w symulacjach klimatycznych, integrując dynamicznie zmienne wejścia z modeli o niższej rozdzielczości (downscaling) przy drastycznie zredukowanym koszcie inferencji.[14] Analiza map atencji pokazuje, że Vision Transformery zdolne są wychwycić oddziaływania atmosferyczne z drugiego końca globu planetarnego, co przy badaniu zjawisk oscylacji temperatury oceanu na ciałach niebieskich daje niespotykaną przewagę poznawczą.

Zestawienie możliwości poszczególnych technologii przedstawia Tabela 1, rygorystycznie mapując zastosowania w domenach.

Architektura Obliczeniowa	**Zarządzanie Zależnościami Czasoprzestrzennymi**	**Odporność na Błąd Spektralny**	**Zastosowanie w Cyfrowym Bliźniaku Astrobiologicznym**
Klasyczny PINN	Słaba (lokalne uwięzienie,	Niska (rozmywa ostre gradienty	Modelowanie prostego 1D

(MLP)	optymalizacja gradientowa punktowa)	termodynamiczne) [7]	balansu energii planety.
Ensemble ELM	Średnia (wymaga zespołowej agregacji, brak globalnej struktury)	Brak rygoru PDE (polega na estymacji danych tabelarycznych) [1]	Błyskawiczna emulacja tabel widm atmosferycznych dla szybkiego prototypowania.[1]
PINNsFormer	Bardzo wysoka (mechanizm Multi-Head Attention na pseudoskwencjach) [4]	Bardzo wysoka (rozpoznaje zachowania wysokoczęstotliwościowe, funkcja Wavelet) [4]	Sferyczna symulacja przepływu ciepła przez linię terminatora na planetach zablokowanych pływowo.
Vision Transformer (ViT)	Absolutna (globalny kontekst przez podział obrazów z zachowaniem rozdzielczości) [15]	Wysoka (lepiej przetwarza złożone interakcje chmur i lodu niż CNN) [16]	Generowanie map ułamka lodu morskiego i opadów jako surogat modeli ROCKE-3D GCM w trybie ciągłym.

Tabela 1. Analiza krytyczna i architektoniczna algorytmów na potrzeby rygorystycznego mapowania w cyfrowych bliźniakach.

Kategoria 1 Hackathonu: Cyfrowe Bliźniaki w Początkach Życia (Origins of Life)

Kategoria pierwsza wymaga od zespołów projektowych zgłębienia procesów przejścia materii abiotycznej w struktury biochemiczne. Teoretyczne hipotezy, takie jak świat RNA, metabolizm-najpierw (metabolism-first) czy świat lipidów, zakładają wyłonienie się samoorganizacji w specyficznych niszach dostarczających energii, takich jak kominy hydrotermalne, baseny pływowe czy przestrzenie podlodowcowe na młodej Ziemi.[1] Historycznie, chemiczne i fizyczne modelowanie tych sieci reakcji, które w geologicznej skali czasu skutkowały zdarzeniami samoreplikacji, stanowiło monumentalne wyzwanie z uwagi na

geometrycznie narastającą przestrzeń kombinatoryczną i mnogość parametrów środowiskowych.[21] Wymagania hackathonu kładły nacisk na budowę probabilistycznych symulacji, np. opartych na procesie Poissona, gdzie prawdopodobieństwo pojawienia się życia eksponencjalnie rośnie względem badanej zmiennej.[1] Niemniej jednak wkroczenie Generatywnej Sztucznej Inteligencji (GenAI) i potężnych agentów opartych na Wielkich Modelach Językowych (LLM) zredefiniowało standard modelowania prebiotycznego, dostarczając inżynierom oprogramowania mechanizmów deklasujących proste estymacje matematyczne.

GenAI, Prawo Zachowania Masy i Modele Sieci Reakcji

Zastosowanie uczenia maszynowego w badaniach chemicznych opierało się dawniej na symulacjach dynamiki molekularnej "ab initio" czy estymacjach kwantowych, co w warunkach modelowania miliardów możliwych reakcji na wczesnej Ziemi jest całkowicie niewykonalne.[20] Aktualny paradygmat bazuje na modelach językowych, które w środowisku chemicznym mapują przestrzenie molekularne reprezentowane w postaci ciągów znaków (np. SMILES), traktując chemię jak rygorystyczny język strukturalny.[24] Wczesne wdrożenia LLM cierpiały na halucynacje, proponując nieprawdopodobne szlaki syntezy ignorujące fundamenty takie jak prawo zachowania masy, co dyskwalifikowało je w nauce o rygorystycznych parametrach stechiometrycznych.[25] Jednak zintegrowanie architektur Transformerowych z reprezentacjami fizycznie spójnymi, w których przewidywania wymuszane są do zachowania równowagi ubytków i zysków izotopowych, drastycznie podniosło dokładność predykcji reakcji dla całych sieci.[25] Modele takie jak te łączone z mechanizmami uczenia maszynowego nadają dynamice sieciowej (np. oscylacje stężeń w modelach autokatalizy) nowe, deterministyczne obramowanie.[20] Zespoły mogą wdrożyć wytrenowane predyktory LLM posiłkujące się bibliotekami interakcji, co pozwala maszynie analizować setki tysięcy potencjalnych reakcji z surowych molekuł budulcowych.[27]

LLM Agents w Zarządzaniu Symulacjami (ChemCrow i Coscientist)

Zasadniczy przełom nie polega wyłącznie na zmuszeniu sieci neuronowej do zwracania nazw molekuł, ale na wyposażeniu wielkich modeli (typu Llama-3-70B czy GPT-4) w ramy agentowe (Agentic AI) zdolne do wchodzenia w interakcje ze środowiskiem w pętli Reason-and-Act (ReAct).[29] Architektury takie jak ChemCrow czy AI Co-Scientist przekształcają pasywny model w autonomicznego naukowca zdolnego do wykonania skomplikowanych doświadczeń.[29] System ten posiada zintegrowany zestaw wywołań zwrotnych (tools/API), które pozwalają agentowi:

1. Pobierać specyfikacje historyczne z kuratorowanych baz danych reakcji prebiotycznych takich jak ChemOrigins (bazy opartej na wiedzy eksperymentalnej zorganizowanej w formie grafów połączonych mechanizmów abiotycznych).[34]
2. Wykonywać skrypty Python uruchamiające algorytmy różniczkowe kontrolujące zmienne fizyczne.

3. Wykorzystywać Retrieval-Augmented Generation (RAG) do weryfikowania stabilności oligomerów względem zasobów energii wyciągniętej z abstrakcyjnych formuł.[22]

Podczas gdy tradycyjny projekt na hackathonie mógłby wymagać twardego zakodowania wskaźników stabilności RNA w odpowiedzi na rosnącą temperaturę, model wieloagentowy (np. zbudowany na frameworku ChemAgents) deleguje poszczególne zadania do wyspecjalizowanych sub-agentów (czytacz literatury, projektant eksperymentu, operator obliczeń) organizując kompleksową infrastrukturę.[30] Agent analizuje wpływ czynników zakłóceniowych, samodzielnie naprawia błędy w skryptach symulacji termicznej, iteruje konfigurację i dąży do uzyskania optymalnego prawdopodobieństwa zajścia replikacji bez ingerencji człowieka.[31]

Koncepcja Projektowa: Zautomatyzowany Agent Modelujący Środowisko Prebiotyczne

Integracja technologii generatywnych pozwala na wdrożenie imponującej, natychmiastowo gotowej do prezentacji platformy w ciągu zaledwie 72 godzin:

- **Architektura Implementacji:** Budowa hybrydowego interfejsu w środowisku Streamlit, z podpiętym backendem wykorzystującym modele z serii Smolagents lub LangChain powiązane z wirtualnym systemem rozwiązywania układów równań chemicznych.[37]
- **Realizacja Eksperymentu:** Użytkownik zleca Agentowi LLM poprzez naturalny interfejs: "Zbadaj warunki komina hydrotermalnego, zoptymalizuj energię cieplną dla uzyskania stabilności RNA, biorąc pod uwagę limitowane dostawy nukleotydów". Agent autorytatywnie przetwarza parametry z bazy ChemOrigins, dokonuje wywołań w tle rozwiązując macierze kinetyczne procesów Poissona, weryfikuje ich rygor termodynamiczny i renderuje dynamiczny wykres ewolucyjnego tempa tworzenia długich polimerów.[22]
- **Implikacje Edukacyjne i "Efekt WOW":** Wynik zderzenia abstrakcyjnego wymuszania obliczeń chemicznych z płynnością sztucznej inteligencji, potrafiącej logicznie uzasadniać (chain-of-thought) ograniczenia narzucone przez ubytki stężeń surowców, dostarczy sędziom zjawiskowej syntezy nowożytnego oprogramowania asystującego, które docelowo znajdzie wdrożenia w największych platformach poszukiwawczych. Zastępuje to trywialne ramy matematyczne inteligentnym asystentem decyzyjnym radzącym sobie z niestacjonarnymi danymi i ubywającymi strukturami chemicznymi.[42]

Kategoria 2 Hackathonu: Detekcja Życia, Modele Wizyjne i Cyfrowe Zjawiska Biosygnatur

Analiza w przestrzeni poszukiwań dowodów na istnienie obcych struktur życiowych obraca się wokół bezbłędnej interpretacji krzywych zmian blasku fotometrycznego oraz danych spektroskopowych pobieranych ze współczesnych kosmicznych obserwatoriów.[1] Klasyczne systemy identyfikacyjne opierały się na uczeniu konwolucyjnych sieci neuronowych (CNN),

które by zaklasyfikować fałszywe zjawiska gwiazd podwójnych czy plamy słoneczne poddawano na rygorowi sfałdowania fazowego (phase-folding) na bazie ustalonego wariantu czasowego.[9] Współcześnie detekcja ewoluuje w ułamku sekundy dzięki implementacji architektur wielogłowicowej samo-uwagi w badaniach optycznych oraz rewolucji przetwarzania pasm podczerwieni z JWST.[9]

Detekcja Tranzytów przez Modele Transformerowe

Przełomem ogłoszonym w ostatnich latach jest wdrożenie transformatorów przestrzennych do interpretacji pełnych kadrów z misji TESS (Full Frame Images). Ponieważ Transformery fenomenalnie wychwytują zależności w bardzo odległych partiach sekwencyjnych (dzięki nieskończonemu obiegowi pamięci w przeciwieństwie do wąskich w czasie okien LSTM), mogą one pochłaniać strumienie zmian fotometrycznych bezpośrednio bez wymuszania fałdowania.[9] Wyuczenie modelu charakterystyki geometrycznej zjawiska ubytku promieniowania planetarnego (transit dip) pozwala sieci oddzielić subtelne szumy aktywności gwiezdnej od autentycznych detekcji małych planet skalistych, co umożliwiło w badaniach identyfikację nowych kandydatów uchodzących uwadze standardowych algorytmów analitycznych (w tym rzadkie przypadki jedno-tranzytowe lub multi-planetarne, radząc sobie genialnie z niezbalansowanym rozkładem okresów).[9] Fuzja CNN przetwarzających lokalnie kształt pikseli z koderami Transformer modelującymi długoterminowy sygnał czasowy stanowi złoty standard detekcji, dający na zsyntetyzowanych danych astronomicznych skuteczność rzędu 100% precyzji w wychwytywaniu ciał niebieskich z tłumu interferencji i quasi-statycznego zjawiska plamek optycznych na koronografach bezpośredniego obrazowania.[47]

Rewolucja Odzyskiwania Widm (Atmospheric Retrieval) Teleskopu Webba

Astrobiologiczna diagnoza opiera się o weryfikację składu atmosfer po uwzględnieniu m.in. gazów biogennych, takich jak metan, ozon czy dwutlenek węgla w spektrum transmitowanym światła.[1] Dotychczas, weryfikowanie tych stężeń było gigantycznym obciążeniem, jako że modele odwracania (retrieval models) takie jak VIRA, CHIMERA, czy moduły platformy NEXOTRANS operowały na skomplikowanej statystyce w poszukiwaniu wiarygodnych parametrów na bazie inferencji Bayesowskiej (korzystając ze standardowych łańcuchów MCMC) oraz modeli transportu radiacyjnego, analizując dziesiątki tysięcy scenariuszy ciśnień i rzutowań promieniowania na sferę gwiezdną przez powłokę atmosfery egzoplanety.[44] Złożone ramy wymuszały iteracje opóźniając generację wyników przy setkach potencjalnych kandydatów.[1]

Implementacja algorytmów z pogranicza Transformer, takich jak Spectrum Transformer (SpT), natychmiastowo przyspiesza procedurę, eliminując sprzężenia z potężnymi, żarłocznymi na zasoby algorytmami transportowymi.[54] Przepuszczając informacje geometryczne i fizykochemiczne w postaci ukrytych tokenów w układach wektorowych kodera uwarunkowań, model maszynowy potrafi emulować widma wysokorozdzielcze (nawet R=100,000 dla

instrumentów o wielkim zysku) lub rekonstruować skład przy ultra-niskim stosunku sygnału do szumu (SNR bliskie 4, pospolite przy odczytach małych planet w pobliżu karłów M jak TRAPPIST-1) bez gubienia informacji na skutek załamań widm i rozpraszania Rayleigha lub Miego w układach uwarstwionych tlenków i aerozoli krzemianowych.[44] GenAI stwarza również podwaliny do przewidywania syntetycznych obcych biosygnatur.

Koncepcja Projektowa: Błyskawiczny Odtwarzacz Syntetycznych Egzosfer (Transformer Retrieval Pipeline)

Propozycja wykorzystująca GenAI w symulacjach staje w opozycji do starszych standardów, operujących klasycznymi drzewami regresyjnymi czy ułomnymi topologiami CNN.[1]

- **Innowacyjny Silnik Odzyskiwania (Retrieval Agent):** Architektura pobierająca fałszywie zaszumione (zasymulowane) dane z teleskopu za pośrednictwem serwerów takich jak Planetary Spectrum Generator (PSG) dostarczający syntetycznych linii widmowych.[1]
- **Wdrożenie Oparte na Transformerze:** Implementacja architektury z rodziny Flow Matching lub pre-trenowanego Spectrum Transformera potrafiącego przyjąć sygnał i, bazując na ukrytym potężnym mechanizmie śledzenia globalnym pasm absorpcyjnych gazów (np. pasm metanu w podczerwieni ok. 3.3 µm i ozonu ok. 9.6 µm), predykować rozkłady prawdopodobieństwa obfitości moli cząsteczek.[44]
- **Interfejs "Efektu WOW":** Platforma ocenia za pomocą wygenerowanego LLM zarysu narracji wiarygodność wystąpienia warunków habitatywnych. Sędzia dostaje czysty plik sygnału – algorytm oparty na głębokiej architekturze dekoduje stężenia izotopowe w sekundę, wypluwając ostateczny werdykt i klasyfikując ciało do "potencjalnych środowisk podobnych do eonów Ziemi z okresu Proterozoiku" po weryfikacji sprzężeń między zjonizowanym tlenem a metanem.[50]

Kategoria 3 Hackathonu: Fundacyjne LLM i Bliźniaki Zdatności Egzoplanetarnej

Ewaluacja warunków istnienia wody, a co za tym idzie zdatności egzoplanety do życia, polega w klasycznych systemach na budowie ułamków uwarunkowań ciśnień oraz temperatury, które mogą ewoluować podczas dziesiątek lat wymuszanej synchronizacji orbitalnej (Tidal Locking).[1] Współczesna inżynieria astrofizyczna bazująca na NASA Exoplanet Archive (dostępnych w ustrukturyzowanych relacyjnych układach przez protokół zapytań SQL i TAP [1]) napotkała zator analizacyjny wynikający ze sztywnego przypisywania wyników przez modele uboższych statystycznie wymiarów.[61] Integracja nowoczesnych fundacyjnych algorytmów (Large Foundation Models) modyfikuje pojęcie budowania Cyfrowych Bliźniaków.[62]

Powstanie Kosmicznych Modeli Fundacyjnych (AstroLLaMA / AstroBERT)

Wielkie modele językowo-naukowe ukierunkowane wyłącznie na astronomię (domain-specific foundation models), do których należą AstroBERT, AstroLLaMA oraz AstroSage, rewolucjonizują wprost pozyskiwanie wniosków.[64] Model AstroSage-LLaMA-3.1-70B wytrenowany potężnym zestawem milionów tokenów literatury dedykowanej wyłącznie astrofizyce jest w stanie uzyskiwać oceny porównywalne z najbardziej wszechstronnymi, nie-specjalistycznymi algorytmami GPT-4, ale z dedykacją ukierunkowaną na wskaźniki gęstości planet czy parametry klasyfikacji.[65] Modele te potrafią działać jako autonomiczni asystenci analizujący archiwum egzoplanet; przyjmują tekst zapytań o warunki poszukiwań "światów w strefie Złotowłosej z masą zbliżoną do Ziemi" i generują zapytania API SQL wyciągające poprawne parametry izolacji i grawitacji z baz.[37] Rozwiązanie zintegrowane w łańcuch dostarczonych narzędzi LangChain automatyzuje zbieranie wskaźników fizycznych (np. wskaźnika ESI) oddzielając sterylnie zimne obiekty od planet umiarkowanych, bez generowania paradoksalnych i fałszywych urojonych wskaźników klas mniejszościowych typowych dla prostej logistyki regresyjnej.[1]

Vision Transformers i Prognozowanie Cyfrowych Bliźniaków Klimatu

Odchodząc z warstwy tekstu na symulację cyrkulacji powierzchniowej dla układów uwięzionych pływowo (Terminator Zone Habitability), głębokie generatywne sztuczne sieci wykraczają znacznie poza dawne koncepcje.[1] Generowanie map klimatu uczy inżyniera budowy precyzyjnych pętli sprzężenia zwrotnego. Podczas gdy starsze systemy stosowały konwolucyjne emulatory U-Net lub stochastyczne ELM dla surogacji GCM, wdrażanie przestrzennych Vision Transformers (Spatiotemporal ViT) pozwala systemowi wypracowywać bezpośrednią reprezentację z coarse-resolution GCM do map wysokiej jakości topograficznych przewidywań temperatury oraz rozkładów prądów morskich.[14] W odróżnieniu od CNN ignorujących dynamikę prądów zachodzących po obu stronach globu, waga uwag globalnych ViT rejestruje powolną dysypację stref w globalnym kontekście bez załamań spowodowanych skomplikowanym kształtem powierzchni niejednorodnych sieci sferycznych wybrzeży i cyrkulacji atmosferycznych.[15] Architektury hybrydowe uwzględniające czas – operujące 4D-Swin Transformery lub Fourier Neural Operators (FNOB/PINN) – dostarczają bezbłędnej mapy gradientu na egzoplanetach z ułamkiem wkładu energetycznego, jaki wymaga klasyczna symulacja modeli ROCKE-3D NetCDF.[1]

Koncepcja Projektowa: Zintegrowany Exo-Asystent z Analizą GCM

Odrzucając skromne, klasyczne modele, projekt uderza bezpośrednio w zapotrzebowanie łączenia narzędzi przez agentów z symulacją 2D/3D zjawisk klimatycznych planety:

- **Interaktywny LLM Orchestrator:** Wyrzucenie sztywnego kodu na rzecz ramy agentowej (Smolagents/LangChain z dostępnym modelem AstroLLaMA lub innym potężnym wskaźnikiem) połączonym do bibliotek danych.[37]
- **Potok Predykcyjny (Data Fetching):** Badacz wywołuje prośbę na interfejsie przeglądarkowym. Agent z marszu wykorzystuje funkcje API zaciągające obiekty np. o

odpowiednim promieniu z Archiwum Exoplanet NASA (dane z TAP) i oblicza dla nich ESI lub stabilność rezonansu tidal-locking.[1]

- **Błyskawiczny Surogat Klimatu (Climate ViT Surrogate):** Po wskazaniu docelowej, obiecującej planety, skrypt automatycznie przepuszcza zrekalkulowane zmienne brzegowe (S, A, ω_s) przez gotowego pre-trenowanego Vision Transformera lub strukturę PINNsFormer.[6] Powstaje błyskawiczne numeryczne mapowanie obszaru powierzchni z temperaturą powyżej zera z uwzględnieniem cyrkulacji wodnych (z wyeksponowaniem "efektu termostatu strefowego homara").[1]
- **Efekt WOW:** Prezentacja integruje dynamiczne wskaźniki wizualizacyjne i dyskursję tekstową agenta na żywo; jest dowodem mistrzowskiego operowania hybrydowymi systemami AI oraz predykcji ekstremalnych praw fizyki na modelach nieprzekraczalnych wymogów, omijającym problem halucynacji LLM.

Ewaluacja Wykonalności Strategii i Zaleceń Narzędziowych na Hackathonie

Podstawowe wyzwanie postawione przez formułę wydarzenia to ekstremalnie krótki czas programowania (typowo ok. 72-96 godzin) oraz bardzo ograniczona dostępność monstrualnych zasobów klastrów GPU, niezbędnych dla swobodnego manipulowania wielomiliardowymi modelami sieci z uwagą (Attention-based models) w fazie pełnego treningu (Full Fine-Tuning).[7,4] Użytkownik w swoim zapytaniu porusza zasadniczą kwestię opłacalności wdrożenia narzędzi LLM/Transformers względem wcześniejszych zaleceń (np. PINN, Extreme Learning Machines czy hybrydowych narzędzi zespołowych). Obiektywna diagnoza sprowadza się do zestawienia ryzyka, zbieżności czasowej modeli i oszałamiającego wpływu gotowego prototypu (tzw. "Efekt WOW") na oceniających.[1]

Bariera Czasu Treningu: Transformer vs. ELM / PINN

Klasyczne sieci PINN, zważywszy na konieczność balansowania współczynników straty λ do wyodrębnienia praw różniczkowania, jak i same, surowe Transformery Wizyjne ulegające bez pre-trenowanych ram ciężkiemu głodowi na dane, mogą stać się potężną kulą u nogi z opóźnieniami konwergencji rozciągającymi się na godziny po każdej iteracji.[1] Modele Extreme Learning Machines (ELM) z randomizacją stochastyczną wag oferują bezdyskusyjną korzyść czasu kalibracji – uczą się parametrów surogacyjnych GCM w niemalże mgnieniu oka, deklasując modele głębokie w kwestii prędkości ewaluacji na przeciętnym sprzęcie deweloperskim.[1] *Jeżeli cel polega na absolutnym skonstruowaniu silnika numerycznego od surowego zera, pozbawionego zewnętrznych bibliotek fundacyjnych czy gotowych wag dla np. PINNsFormer,* wybór narzędzi z grupy maszyn ELM lub prostych i lekkich bibliotek jak XGBoost jest taktycznie bezdyskusyjny do zwalczenia błędu czasowego i doprowadzenia interfejsu sferycznego do premiery.[1]

Bezwzględna Wartość Innowacji Agentowych (GenAI)

Jeżeli jednak zespół pragnie przekroczyć barierę trywialnej analityki tabelarycznej lub wrysowywania statystyk we wzory – modele GenAI opierające się na narzędziach do podłączania logiki zewnętrznej (np. pętla *LangChain* lub *Agent-based workflows*) stanowią gigantyczną dźwignię przewagi konkurencyjnej. Narzędzia takie jak asystenci w pełni autonomiczni potrafią przejąć na siebie żmudny proces preparacji danych (parsing API z NASA Archive czy Planetary Spectrum Generator) co redukuje wielogodzinne zadanie żmudnego kodowania żądań GET do zaledwie kilku komend naturalnego języka z opcją generacji (Function Calling).[1] Integracja autonomicznego agenta tworzy iluzję stworzenia niezwykle futurystycznego asystenta planetarnego z wbudowaną kompetencją analityczną.

Wypośrodkowanie - Rekomendowana Architektura Hybrydowa (Hybrid SciML)

Badania wskazują, że potężne modele czysto LLM są zawodne w naukach przyrodniczych, jeżeli nie stosuje się rygorystycznego weryfikatora. Sieci potrafią nagminnie i niepostrzeżenie zmyślać zjawiska zachowania masy i ewolucji chemicznej, gubiąc realizm fizyczny w morzu semantyki wektorowej.[25] Idealnym rozwiązaniem dla ambitnej drużyny z HACK-4-SAGES jest zatem stworzenie *Cyfrowego Bliźniaka w architekturze Hybrydowej (SciML)*.[75]

1. **Warstwa Logiki i Interakcji (Orchestration):** Budowa front-endu w Pythonie (np. Streamlit) operującego na szkielecie Agentic LLM (np. wywołania przez API lekkich, ale precyzyjnych pre-trenowanych asystentów jak z linii LLaMA/GPT-4 do zapytań o warunki początkowe, weryfikacji bazy i generacji podsumowań statystycznych).[37] Zdejmuje to konieczność ciężkiego pisania parserów oraz nadaje panelowi natychmiastowy potężny rys innowacyjny.
2. **Warstwa Silnika Fizycznego (Physics/Math Engine):** Gdy asystent zidentyfikuje konfigurację planety i jej parametry, musi kategorycznie wezwać zewnętrzne funkcje wykonawcze odpowiedzialne za twarde liczby. Rolę emulacji gradientów termodynamicznych na planecie zablokowanej oddaje się błyskawicznym sieciom w architekturze ensemble ELM [1], lekkim usztywnionym równaniom implementowanym w sieciach typu PINN, bądź zewnętrznym generatorom spektroskopowym (NEXOTRANS czy Spectrum Transformer korzystającym z pre-trenowanych wag).[44] Moduł generuje wektor danych topograficznych i widm, nie dając agentowi szansy na wyimaginowane fałszerstwa (halucynacje fizyczne).
3. **Warstwa Wizualizacji (Output):** Konkluzja i gotowe macierze przestrzenne są dynamicznie rzutowane na mapy sferyczne, dając sędziom zjawiskowy dowód na w pełni ustrukturyzowany, naukowo rygorystyczny aparat wnioskowania planetarnego.[1]

Zastosowanie tych technologii wektorowych transformuje platformę ze zbioru jednowymiarowych statystyk w fascynującego wirtualnego obserwatora odległych światów. Integracja rygorystycznych rozwiązań na poziomie fizyki cząstkowej połączona z inteligencją

werbalną i organizacyjną (Generative AI) zapewnia deklasującą oryginalność względem podstawowych podejść ewaluacyjnych klasyfikujących cyfrowe sfery w binarnej ocenie zdatności. Wyrzeczenie się asysty LLM na rzecz pozostania wyłącznie przy starych propozycjach zuboża projekt w jego wymiarze eksploracyjnym, podczas gdy oparcie systemu całkowicie na samym generatorze słów kompromituje fizyczny sens przedsięwzięcia. Balans, reprezentowany przez omówione wyżej hybrydy agentowo-matematyczne, gwarantuje bezkompromisowy status faworyta podczas ostatecznych prezentacji.

Cytowane prace

1. Hackathon_ Egzoplanety i AI.pdf
2. Towards Scientific Intelligence: A Survey of LLM-based Scientific Agents - arXiv, otwierano: lutego 22, 2026, https://arxiv.org/html/2503.24047v3
3. [2407.01603] A Review of Large Language Models and Autonomous Agents in Chemistry, otwierano: lutego 22, 2026, https://arxiv.org/abs/2407.01603
4. PINNsFormer: A Transformer-Based Framework For Physics-Informed Neural Networks, otwierano: lutego 22, 2026, https://huggingface.co/papers/2307.11833
5. PINNs vs MLP vs Transformers: Why PINNs outperform in Physics-Driven Tasks - Medium, otwierano: lutego 22, 2026, https://medium.com/@rohandgkp/pinns-vs-mlp-vs-transformers-why-pinns-outperform-in-physics-driven-tasks-595661ccc524
6. Physics-Informed Transformer Networks - OpenReview, otwierano: lutego 22, 2026, https://openreview.net/pdf?id=zu80h9YryU
7. Physics-Informed Deep Learning for Transformer Thermal Modelling: Possibilities and Limitations - Diva-portal.org, otwierano: lutego 22, 2026, https://www.diva-portal.org/smash/get/diva2:1905716/FULLTEXT01.pdf
8. Physics-Informed Neural Networks for prediction of transformer's temperature distribution, otwierano: lutego 22, 2026, https://ieeexplore.ieee.org/document/10068906/
9. Exoplanet Transit Candidate Identification in TESS Full-Frame Images via a Transformer-Based Algorithm - Astrobiology, otwierano: lutego 22, 2026, https://astrobiology.com/2025/02/exoplanet-transit-candidate-identification-in-tess-full-frame-images-via-a-transformer-based-algorithm.html
10. A Practical Survey on Faster and Lighter Transformers - arXiv.org, otwierano: lutego 22, 2026, https://arxiv.org/pdf/2103.14636
11. PhysicsFormer: An Efficient and Fast Attention-Based Physics-Informed Neural Network for Solving Incompressible Navier–Stokes Equations - arXiv.org, otwierano: lutego 22, 2026, https://arxiv.org/html/2601.03613v1
12. PhysicsFormer: Transformer PINN Framework - Emergent Mind, otwierano: lutego 22, 2026, https://www.emergentmind.com/topics/physicsformer
13. PINNsFormer: A Transformer-Based Framework For Physics-Informed Neural Networks, otwierano: lutego 22, 2026, https://arxiv.org/html/2307.11833v3
14. (PDF) Vision Transformers for Multi-Variable Climate Downscaling: Emulating Regional Climate Models with a Shared Encoder and Multi-Decoder Architecture - ResearchGate, otwierano: lutego 22, 2026,

https://www.researchgate.net/publication/393183867_Vision_Transformers_for_Multi-Variable_Climate_Downscaling_Emulating_Regional_Climate_Models_with_a_Shared_Encoder_and_Multi-Decoder_Architecture
15. A Fast AI Surrogate for Coastal Ocean Circulation Models - arXiv.org, otwierano: lutego 22, 2026, https://arxiv.org/html/2410.14952v1
16. Vision Transformers vs. Convolutional Neural Networks | by Fahim Rustamy, PhD | Medium, otwierano: lutego 22, 2026, https://medium.com/@faheemrustamy/vision-transformers-vs-convolutional-neural-networks-5fe8f9e18efc
17. Comparing Vision Transformers and Convolutional Neural Networks for Image Classification: A Literature Review - MDPI, otwierano: lutego 22, 2026, https://www.mdpi.com/2076-3417/13/9/5521
18. Digital Twin Framework with Spatiotemporal Vision Transformers for Heat Resilience, otwierano: lutego 22, 2026, https://i-guide.io/i-guide-vco/digital-twin-framework-with-spatiotemporal-vision-transformers-for-heat-resilience/
19. Frequency-Aware Vision Transformers for High-Fidelity Super-Resolution of Earth System Models - arXiv, otwierano: lutego 22, 2026, https://arxiv.org/html/2502.12427v4
20. Computational studies of prebiotic chemistry at the age of machine learning - ChemRxiv, otwierano: lutego 22, 2026, https://chemrxiv.org/doi/pdf/10.26434/chemrxiv-2025-4qvdz
21. Automated Exploration of Prebiotic Chemical Reaction Space: Progress and Perspectives - PMC, otwierano: lutego 22, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC8624352/
22. Prebiotic Resource Constraints and the Origin of Life: A Linear Logic Framework - bioRxiv.org, otwierano: lutego 22, 2026, https://www.biorxiv.org/content/10.1101/2025.03.23.644802v1.full.pdf
23. Computational Discovery of the Origins of Life - PMC - NIH, otwierano: lutego 22, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC6764069/
24. A Transformer Model for Predicting Chemical Reaction Products from Generic Templates, otwierano: lutego 22, 2026, https://arxiv.org/html/2503.05810v2
25. A new generative AI approach to predicting chemical reactions | MIT News, otwierano: lutego 22, 2026, https://news.mit.edu/2025/generative-ai-approach-to-predicting-chemical-reactions-0903
26. DENG-MIT/CRNN: Chemical Reaction Neural Network - GitHub, otwierano: lutego 22, 2026, https://github.com/DENG-MIT/CRNN
27. Generative AI for navigating synthesizable chemical space - PNAS, otwierano: lutego 22, 2026, https://www.pnas.org/doi/10.1073/pnas.2415665122
28. General-Purpose Models for the Chemical Sciences: LLMs and Beyond - ACS Publications, otwierano: lutego 22, 2026, https://pubs.acs.org/doi/10.1021/acs.chemrev.5c00583
29. Sam Cox, Automating Chemistry With LLM-Based Agents; Primer: Andrew White, otwierano: lutego 22, 2026,

https://www.broadinstitute.org/videos/sam-cox-automating-chemistry-llm-based-agents-primer-andrew-white
30. A multi-agent-driven robotic AI chemist enabling autonomous chemical research on demand | ChemRxiv, otwierano: lutego 22, 2026, https://chemrxiv.org/doi/full/10.26434/chemrxiv-2024-w953h-v2
31. Autonomous chemical research with large language models - PMC - NIH, otwierano: lutego 22, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC10733136/
32. Accelerating scientific breakthroughs with an AI co-scientist - Google Research, otwierano: lutego 22, 2026, https://research.google/blog/accelerating-scientific-breakthroughs-with-an-ai-co-scientist/
33. ChemCrow: Augmenting large-language models with chemistry tools - arXiv.org, otwierano: lutego 22, 2026, https://arxiv.org/abs/2304.05376
34. ChemOrigins: A community curated database for origins of life chemistry - bioRxiv, otwierano: lutego 22, 2026, https://www.biorxiv.org/content/10.1101/2025.06.10.658922v2.full.pdf
35. ChemOrigins: a community-curated database for origins-of-life chemistry | Interface Focus, otwierano: lutego 22, 2026, https://royalsocietypublishing.org/rsfs/article/doi/10.1098/rsfs.2025.0034/364680/ChemOrigins-a-community-curated-database-for
36. ChemOrigins: A community curated database for origins of life chemistry - bioRxiv, otwierano: lutego 22, 2026, https://www.biorxiv.org/content/10.1101/2025.06.10.658922v3.full.pdf
37. NASA-IMPACT/LLM-cookbook-for-open-science: Cookbook to use LLMs effectively for sciences, in various levels of expertise - GitHub, otwierano: lutego 22, 2026, https://github.com/NASA-IMPACT/LLM-cookbook-for-open-science
38. The AI Cosmologist I: An Agentic System for Automated Data Analysis - arXiv.org, otwierano: lutego 22, 2026, https://arxiv.org/html/2504.03424v1
39. Agentic AI for Scientific Discovery: A Survey of Progress, Challenges, and Future Directions, otwierano: lutego 22, 2026, https://arxiv.org/html/2503.08979v1
40. Building AI agents using HF Smolagents | by Fatimah Sammar | Medium, otwierano: lutego 22, 2026, https://medium.com/@fatsammar/building-ai-agents-using-hf-smolagents-d21e514786e4
41. Evolution in chemical reaction networks and the origins of biochemical life - Confex, otwierano: lutego 22, 2026, https://agu.confex.com/agu/abscicon24/meetingapp.cgi/Paper/1498757
42. LifeLong Learning for Large Language Models in Predicting Chemical Reaction Yields | ChemRxiv, otwierano: lutego 22, 2026, https://chemrxiv.org/doi/full/10.26434/chemrxiv-2025-xtvpc
43. Detection of Exoplanets in Transit Light Curves with Conditional Flow Matching and XGBoost - MDPI, otwierano: lutego 22, 2026, https://www.mdpi.com/2079-9292/14/9/1738
44. A Next-Generation Exoplanet Atmospheric Retrieval Framework for Transmission Spectroscopy (NEXOTRANS): Comparative Characterization for WASP-39 b Using

JWST NIRISS, NIRSpec PRISM, and MIRI Observations - Astrobiology, otwierano: lutego 22, 2026, https://astrobiology.com/2025/05/a-next-generation-exoplanet-atmospheric-retrieval-framework-for-transmission-spectroscopy-nexotrans-comparative-characterization-for-wasp-39-b-using-jwst-niriss-nirspec-prism-and-miri-observation.html
45. Exoplanet Transit Candidate Identification in TESS Full-Frame Images via a Transformer-Based Algorithm - arXiv, otwierano: lutego 22, 2026, https://arxiv.org/html/2502.07542v2
46. Exoplanet transit candidate identification in TESS full-frame images via a transformer-based algorithm - Oxford Academic, otwierano: lutego 22, 2026, https://academic.oup.com/mnras/article/538/3/2031/8043272
47. Machine learning revolution for exoplanet direct imaging detection: transformer architectures, otwierano: lutego 22, 2026, https://arxiv.org/html/2508.14508v1
48. Identifying Exoplanets with Deep Learning: A CNN and RNN Classifier for Kepler DR25 and Candidate Vetting - arXiv, otwierano: lutego 22, 2026, https://arxiv.org/html/2509.04793v1
49. Machine Learning Revolution For Exoplanet Direct Imaging Detection: Transformer Architectures - Astrobiology, otwierano: lutego 22, 2026, https://astrobiology.com/2025/08/machine-learning-revolution-for-exoplanet-direct-imaging-detection-transformer-architectures.html
50. Machine-assisted classification of potential biosignatures in Earth-like exoplanets using low signal-to-noise ratio transmission spectra - Oxford Academic, otwierano: lutego 22, 2026, https://academic.oup.com/mnras/article/539/2/1528/8109635
51. [2403.04825] VIRA: An Exoplanet Atmospheric Retrieval Framework for JWST Transmission Spectroscopy - arXiv, otwierano: lutego 22, 2026, https://arxiv.org/abs/2403.04825
52. mrline/CHIMERA: Atmospheric Retrieval Codes for Exoplanets - GitHub, otwierano: lutego 22, 2026, https://github.com/mrline/CHIMERA
53. A Next-Generation Exoplanet Atmospheric Retrieval Framework for Transmission Spectroscopy (NEXOTRANS): Comparative Characterization for WASP-39 b Using JWST NIRISS, NIRSpec PRISM, and MIRI Observations - ResearchGate, otwierano: lutego 22, 2026, https://www.researchgate.net/publication/391247537_A_Next-Generation_Exoplanet_Atmospheric_Retrieval_Framework_for_Transmission_Spectroscopy_NEXOTRANS_Comparative_Characterization_for_WASP-39_b_Using_JWST_NIRISS_NIRSpec_PRISM_and_MIRI_Observations
54. (PDF) Transformer-Based Fast Mole Fraction of CO2 Retrievals from Satellite-Measured Spectra - ResearchGate, otwierano: lutego 22, 2026, https://www.researchgate.net/publication/389464121_Transformer-Based_Fast_Mole_Fraction_of_CO2_Retrievals_from_Satellite-Measured_Spectra
55. [2308.14804] Earth as a Transiting Exoplanet: A Validation of Transmission Spectroscopy and Atmospheric Retrieval Methodologies for Terrestrial Exoplanets - arXiv, otwierano: lutego 22, 2026, https://arxiv.org/abs/2308.14804

56. Technical note: Deep learning for creating surrogate models of precipitation in Earth system models - ACP, otwierano: lutego 22, 2026, https://acp.copernicus.org/articles/20/2303/2020/
57. (PDF) Supervised Machine Learning Methods with Uncertainty Quantification for Exoplanet Atmospheric Retrievals from Transmission Spectroscopy - ResearchGate, otwierano: lutego 22, 2026, https://www.researchgate.net/publication/394396976_Supervised_Machine_Learning_Methods_with_Uncertainty_Quantification_for_Exoplanet_Atmospheric_Retrievals_from_Transmission_Spectroscopy
58. Installation of PSG - Planetary Spectrum Generator, otwierano: lutego 22, 2026, https://psg.gsfc.nasa.gov/help.php
59. atmospheric-retrieval · GitHub Topics, otwierano: lutego 22, 2026, https://github.com/topics/atmospheric-retrieval
60. Machine-assisted classification of potential biosignatures in earth-like exoplanets using low signal-to-noise ratio transmission spectra - arXiv, otwierano: lutego 22, 2026, https://arxiv.org/html/2407.19167v2
61. Classification of dataset of exoplanets(phl_hec_all_confirmed) based on habitability - GitHub, otwierano: lutego 22, 2026, https://github.com/adivar99/Exoplanet-Habitability
62. henrysky/astroNN_stars_foundation: Code for Leung & Bovy 2023 - GitHub, otwierano: lutego 22, 2026, https://github.com/henrysky/astroNN_stars_foundation
63. Enhancing 3D Planetary Atmosphere Simulations with a Surrogate Radiative Transfer Model - ResearchGate, otwierano: lutego 22, 2026, https://www.researchgate.net/publication/382178529_Enhancing_3D_Planetary_Atmosphere_Simulations_with_a_Surrogate_Radiative_Transfer_Model
64. barrosyan/AstroML: This is an on going project to classificate planets weather, using ML. - GitHub, otwierano: lutego 22, 2026, https://github.com/barrosyan/AstroML
65. Welcome to AstroMLab · AstroMLab, otwierano: lutego 22, 2026, https://astromlab.org/
66. yuzhimanhua/Awesome-Scientific-Language-Models - GitHub, otwierano: lutego 22, 2026, https://github.com/yuzhimanhua/Awesome-Scientific-Language-Models
67. AstroMLab/astrollama-3-8b-base_aic - Hugging Face, otwierano: lutego 22, 2026, https://huggingface.co/AstroMLab/astrollama-3-8b-base_aic
68. Hexplorers - NASA Space Apps Challenge, otwierano: lutego 22, 2026, https://www.spaceappschallenge.org/nasa-space-apps-2024/find-a-team/hexplorers/?tab=project
69. Vision Transformers for Multi-Variable Climate Downscaling: Emulating Regional Climate Models with a Shared Encoder and Multi-Decoder Architecture - arXiv, otwierano: lutego 22, 2026, https://arxiv.org/html/2506.22447v1
70. CNNs vs Vision Transformers: A Modern Comparison on Performance, Explainability, and Cost | by Amit Kharche | Medium, otwierano: lutego 22, 2026, https://medium.com/@amitkharche/cnns-vs-vision-transformers-a-modern-comparison-on-performance-explainability-and-cost-4343d366014c

71. Physics-informed surrogate modeling for supporting climate resilience at groundwater contamination sites | Request PDF - ResearchGate, otwierano: lutego 22, 2026, https://www.researchgate.net/publication/376534340_Physics-informed_surrogate_modeling_for_supporting_climate_resilience_at_groundwater_contamination_sites
72. Physics-informed surrogate modeling for supporting climate resilience at groundwater contamination sites - Knowledge UChicago, otwierano: lutego 22, 2026, https://knowledge.uchicago.edu/record/10246/files/Physics-informed-surrogate-modeling-for-supporting-climate-resilience-at-groundwater-contamination-sites.pdf
73. An Examination of Habitability in Exoplanet Systems - Research Archive of Rising Scholars, otwierano: lutego 22, 2026, https://research-archive.org/index.php/rars/preprint/view/14
74. Speeding Up Transformer Training and Inference By Increasing Model Size, otwierano: lutego 22, 2026, https://bair.berkeley.edu/blog/2020/03/05/compress/
75. Bayesian Physics Informed Neural Networks for Reliable Transformer Prognostics | Annual Conference of the PHM Society, otwierano: lutego 22, 2026, https://papers.phmsociety.org/index.php/phmconf/article/view/4344
76. Hybrid Physical Models | Climate Change AI, otwierano: lutego 22, 2026, https://www.climatechange.ai/subject_areas/hybrid_physical_models
77. [2510.27223] A Next-Generation Exoplanet Atmospheric Retrieval Framework NEXOTRANS for Emission Spectroscopy: New Constraints and Atmospheric Characterization of WASP-69b Using JWST NIRCam and MIRI Observations - arXiv, otwierano: lutego 22, 2026, https://arxiv.org/abs/2510.27223